Guía de estudio: Machine Learning
Segundo parcial

Regresión, clasificación y lectura de resultados

Índice

1. Cómo usar esta guía **3**

1.1. Rutina para interpretar cualquier salida 3

2. Aprendizaje supervisado: objetivos y vocabulario **3**

2.1. Explicar no es lo mismo que predecir 4

3. Regresión lineal **4**

3.1. Regresión lineal simple 4

3.2. Regresión lineal múltiple 4

3.3. Predictores categóricos y categorías de referencia 5

3.4. Estimación por mínimos cuadrados ordinarios 5

3.5. Variación explicada y coeficiente de determinación 5

3.6. Errores de predicción 6

3.7. Supuestos y diagnóstico de residuos 6

3.8. Autocorrelación, influencia y valores atípicos 8

3.9. Inferencia para coeficientes y modelo completo 8

3.10. Intervalos de predicción 9

3.11. Comparación de modelos 9

3.12. Regresión polinómica y sobreajuste 9

3.13. Lectura general de una tabla OLS 9

4. Análisis descriptivo y relaciones entre variables **10**

5. Clasificación supervisada y análisis discriminante **10**

5.1. Problema de clasificación y regla de decisión 10

5.2. Análisis discriminante lineal de Fisher 11

6. Evaluación de clasificadores **11**

6.1. Matriz de confusión 11

6.2. Medidas de desempeño . . . 12
6.3. Desbalance de clases, sobremuestreo y SMOTE . . . 13
6.4. Umbral de clasificación y curva ROC . . . 13
6.5. Validación: tasa aparente, holdout y validación cruzada . . . 14

7. Regresión logística binaria **14**
7.1. Por qué no usar regresión lineal para una respuesta binaria . . . 14
7.2. Probabilidad, odds y logit . . . 15
7.3. Interpretación de coeficientes y odds ratio . . . 15
7.4. Estimación y pruebas de hipótesis . . . 15
7.5. Logística predictiva y logística explicativa . . . 16

8. Ejemplos de lectura de los notebooks **16**
8.1. Cuaderno 6: simple, polinómica y múltiple . . . 16
8.2. Cuaderno 7: correlación y regresión OLS . . . 17
8.3. Repaso discriminante y logístico: regresión y residuos . . . 17
8.4. Cuaderno 8: pobreza, odds y métricas . . . 18
8.5. Cuaderno 8: discriminante lineal . . . 18
8.6. Cuaderno 9: clasificación de clientes bancarios . . . 18
8.7. Clase 12: SMOTE, LDA, logística y curva ROC . . . 19
8.8. Repaso discriminante y logístico: evaluación de pobreza . . . 21

9. Errores frecuentes y cómo evitarlos **22**

10. Preguntas de práctica con respuestas modelo **23**

11. Resumen de consulta rápida **25**

1. Cómo usar esta guía

Esta guía integra el teórico de aprendizaje supervisado y regresión, el teórico de clasificación y regresión logística, los notebooks de las unidades 6, 7 (repaso), 8 y 9, la Clase 12 de clasificación supervisada y el cuaderno de repaso discriminante y logística. Está organizada para un parcial escrito y a libro abierto: el objetivo no es reproducir código ni hacer cuentas extensas, sino reconocer qué modelo se ajustó, leer una salida, justificar una interpretación y advertir sus límites.

Las fórmulas aparecen como apoyo para entender e interpretar los resultados. En general, no hace falta calcularlas manualmente. Las secciones conceptuales sintetizan el teórico; la sección de ejemplos traduce las salidas de cada cuaderno. Cuando un ejemplo tiene una inconsistencia, se señala expresamente: conviene razonar a partir de la definición estadística y de la salida completa, no repetir sin revisar una frase o una etiqueta del código.

1.1. Rutina para interpretar cualquier salida

Ante una tabla, un gráfico o una matriz, seguir este orden:

1. Identificar la variable respuesta Y, su tipo y qué significa el valor positivo o la clase 1.
2. Identificar las variables predictoras y la población o muestra a la que se refiere el análisis.
3. Distinguir si el propósito es explicar relaciones o predecir nuevos casos.
4. Revisar qué se informa: coeficientes, pruebas de hipótesis, ajuste, error de predicción o clasificación.
5. Indicar la dirección y el tamaño del resultado en unidades comprensibles, manteniendo constantes las demás variables cuando corresponda.
6. Evaluar significación e incertidumbre sin confundirlas con importancia práctica o causalidad.
7. Verificar cómo se validó el modelo: datos de entrenamiento, validación, prueba o validación cruzada.

2. Aprendizaje supervisado: objetivos y vocabulario

En aprendizaje supervisado se dispone de observaciones etiquetadas, (x_i, y_i), donde x_i contiene las características o variables predictoras y y_i es la respuesta conocida. Se aprende una regla $\widehat{f}$ a partir de esos ejemplos para explicar la relación observada o para predecir la respuesta de casos nuevos.

- **Regresión:** la respuesta es cuantitativa, por ejemplo, consumo, ingresos o ventas. El modelo produce un valor numérico.
- **Clasificación:** la respuesta es categórica, por ejemplo, pobre/no pobre, riesgo bajo/alto o desocupado/ocupado. El modelo estima una clase o una probabilidad de pertenecer a una clase.
- **Entrenamiento:** datos usados para estimar el modelo.
- **Validación:** datos usados para comparar alternativas y elegir ajustes del modelo.
- **Prueba o test:** datos reservados para evaluar el desempeño final en observaciones no usadas para ajustar ni elegir el modelo.

2.1. Explicar no es lo mismo que predecir

Objetivo explicativo: interesa la forma funcional, el signo y la incertidumbre de los coeficientes. La pregunta es cómo se relaciona cada predictor con la respuesta, controlando por los demás. Se interpretan coeficientes, intervalos y pruebas de significación.

Objetivo predictivo: interesa que las predicciones sean acertadas en datos nuevos. Una caja negra puede ser útil si generaliza bien, aunque sus coeficientes no tengan una interpretación sencilla. Se comparan errores o métricas fuera de muestra.

Un buen ajuste sobre los datos de entrenamiento no garantiza buena predicción. La diferencia entre desempeño de entrenamiento y desempeño de validación/test es central para detectar sobreajuste.

3. Regresión lineal

3.1. Regresión lineal simple

Con una respuesta cuantitativa Y y un predictor X, el modelo poblacional es

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i, \qquad E(Y \mid X = x) = \beta_0 + \beta_1 x.$$

La media condicional $E(Y \mid X = x)$ es la respuesta promedio esperada para observaciones con valor $X = x$. ε_i reúne variaciones no explicadas por el modelo.

En el modelo estimado,

$$\widehat{Y}_i = \widehat{\beta}_0 + \widehat{\beta}_1 X_i, \qquad e_i = Y_i - \widehat{Y}_i.$$

El residuo e_i es la diferencia observada para un caso entre su respuesta real y la ajustada. Un residuo positivo significa que el valor real supera la predicción; uno negativo, que queda por debajo.

- $\widehat{\beta}_0$ (intercepto) es la respuesta ajustada cuando $X = 0$. Puede carecer de sentido sustantivo si $X = 0$ no es posible o queda fuera del rango observado.
- $\widehat{\beta}_1$ (pendiente) es el cambio promedio estimado en Y ante un aumento de una unidad de X. El signo indica dirección; el tamaño depende de las unidades.
- Una asociación lineal no prueba por sí sola una relación causal. Puede haber variables omitidas, selección o confusión.

Ejemplo de lectura: si $\widehat{Y} = 0{,}70 + 0{,}38X$, cada unidad adicional de X se asocia con un aumento medio estimado de 0,38 unidades en Y. No significa que cada observación aumente exactamente eso, ni demuestra que cambiar X cause el cambio.

3.2. Regresión lineal múltiple

Con p predictores,

$$E(Y_i \mid X_{i1}, \ldots, X_{ip}) = \beta_0 + \beta_1 X_{i1} + \cdots + \beta_p X_{ip}.$$

El coeficiente $\widehat{\beta}_j$ representa el cambio promedio estimado en Y asociado a un aumento unitario de X_j, **manteniendo fijos los demás predictores del modelo**. Esta condición es lo que distingue la interpretación múltiple de una asociación bivariada.

El intercepto corresponde a que todos los predictores valgan cero. Puede ser una referencia matemática poco realista, pero su presencia suele ser adecuada. Si se quita el intercepto, se impone que la respuesta esperada sea cero cuando todos los predictores son cero; no se debe hacer automáticamente.

Cuidado con las escalas: un coeficiente grande no implica que la variable sea más importante si sus unidades son grandes. Un aumento de una unidad puede significar cosas muy distintas entre años, pesos, porcentajes y categorías.

3.3. Predictores categóricos y categorías de referencia

Una categoría no siempre debe tratarse como una cantidad numérica. Si se representa una variable categórica mediante indicadores, una categoría queda como referencia y cada coeficiente compara otra categoría con esa referencia, manteniendo constantes los demás predictores.

En el notebook de la EPH, el modelo con género usa a Mujer como categoría de referencia. El coeficiente de `x3[T.Varon]` es aproximadamente 4371. La lectura es: para iguales horas trabajadas y edad, el ingreso laboral ajustado para varones es alrededor de 4371 unidades mayor que para mujeres en ese modelo. Es una diferencia asociativa estimada, no un efecto causal automático. Si la variable se codifica simplemente como 1, 2, 3 y se trata como continua, el modelo impone un orden y un efecto por unidad que puede no corresponder a categorías nominales.

3.4. Estimación por mínimos cuadrados ordinarios

Mínimos cuadrados ordinarios (MCO/OLS) elige los coeficientes que minimizan la suma de residuos al cuadrado:

$$\sum_{i=1}^{n}(Y_i - \widehat{Y}_i)^2.$$

Al elevar al cuadrado, los errores grandes pesan más que los pequeños. Con intercepto, algunas propiedades del ajuste MCO son: la suma de residuos es cero; los residuos son ortogonales a los predictores incluidos y a los valores ajustados; y el hiperplano ajustado pasa por el punto de medias de la respuesta y de los predictores. Estas propiedades algebraicas no garantizan que los supuestos del modelo sean ciertos.

Bajo los supuestos de Gauss–Markov (en particular, media condicional del error cero, errores no correlacionados y homoscedasticidad, además de rango completo), MCO es el estimador lineal insesgado de menor varianza entre los estimadores lineales insesgados: se lo llama **BLUE** (*Best Linear Unbiased Estimator*). La normalidad del error no es necesaria para esta propiedad ni para calcular MCO; permite justificar las pruebas e intervalos clásicos exactos en muestras pequeñas. Una estimación usual de la varianza del error es $s^2 = \mathrm{SCE}/(n-p-1)$; $s = \sqrt{s^2}$ es el error estándar residual, una medida de la dispersión típica de los residuos en unidades de Y.

3.5. Variación explicada y coeficiente de determinación

En el modelo lineal con intercepto se descompone la variación observada:

$$\underbrace{\sum_i (Y_i - \bar{Y})^2}_{\text{total, SCT}} = \underbrace{\sum_i (\widehat{Y}_i - \bar{Y})^2}_{\text{explicada, SCR}} + \underbrace{\sum_i (Y_i - \widehat{Y}_i)^2}_{\text{no explicada, SCE}}.$$

$$R^2 = \frac{\mathrm{SCR}}{\mathrm{SCT}} = 1 - \frac{\mathrm{SCE}}{\mathrm{SCT}}.$$

R^2 expresa qué proporción de la variabilidad de Y en la muestra queda explicada por el ajuste lineal. Para el ajuste MCO evaluado en los mismos datos y con intercepto, va de 0 a 1: valores mayores indican mejor ajuste dentro de esa muestra. En una evaluación predictiva sobre datos de prueba puede ser negativo si el modelo predice peor que usar la media de la respuesta de prueba como referencia. No significa porcentaje de casos predichos correctamente, no demuestra causalidad y no prueba que se cumplan los supuestos.

Al sumar predictores, el R^2 ordinario no disminuye aunque el nuevo predictor aporte poco. El R^2 ajustado penaliza en cierta medida agregar predictores y puede servir para comparar modelos de la misma respuesta y muestra. En regresión con intercepto, una forma usual es $\bar{R}^2 = 1 - \frac{n-1}{n-p-1}(1 - R^2)$, donde p es el número de predictores. Ninguno reemplaza la evaluación fuera de muestra.

3.6. Errores de predicción

Para errores $e_i = Y_i - \widehat{Y}_i$:

$$\text{MSE} = \frac{1}{n}\sum_i e_i^2, \qquad \text{RMSE} = \sqrt{\text{MSE}}, \qquad \text{MAE} = \frac{1}{n}\sum_i |e_i|.$$

- **MSE:** penaliza fuertemente errores grandes y queda en unidades al cuadrado de Y.
- **RMSE:** está en las unidades originales de Y; cuanto menor, menor error típico cuadrático.
- **MAE:** error absoluto promedio, también en las unidades originales; es menos sensible a errores extremos que MSE.
- **MedAE:** mediana de los errores absolutos; es más resistente a valores atípicos.
- **RMSLE:** raíz del error cuadrático medio de los logaritmos; compara diferencias relativas de manera más que absoluta y requiere valores compatibles con el logaritmo, usualmente no negativos.

Una métrica baja es favorable solo al comparar la misma respuesta, en escala comparable y sobre datos evaluados de forma equivalente. Un MSE de millones no es automáticamente malo o bueno: depende de la escala de Y y de la referencia con la que se compare.

3.7. Supuestos y diagnóstico de residuos

Los supuestos se refieren principalmente a la estructura de los errores y a la forma condicional de la respuesta, no a que cada predictor tenga distribución normal.

1. **Linealidad de la media:** la relación entre predictores y media de Y está representada adecuadamente por la forma especificada.
2. **Media condicional del error igual a cero:** $E(\varepsilon \mid X) = 0$. En términos prácticos, no queda un patrón sistemático omitido que se relacione con los predictores.
3. **Homoscedasticidad:** la varianza del error es aproximadamente constante a lo largo de los valores ajustados o de los predictores. Si cambia, hay heteroscedasticidad.
4. **Independencia:** los errores de observaciones diferentes no están correlacionados. En datos ordenados en el tiempo puede fallar por autocorrelación.
5. **Normalidad del error:** es importante sobre todo para la inferencia clásica en muestras pequeñas; no es requisito para calcular MCO ni para que toda predicción sea posible.

6. **Predictoras adecuadas:** sin colinealidad perfecta; rango suficiente; relación apropiada con los errores; y mediciones razonablemente correctas. Los coeficientes se consideran constantes en la población modelada.

Gráficos de diagnóstico:

- Residuos frente a predichos o frente a X: una nube aproximadamente aleatoria alrededor de cero es compatible con linealidad y varianza constante. Curvas indican forma funcional faltante; forma de abanico, varianza no constante; grupos o secuencias, estructura no modelada.
- Histograma de residuos: permite ver asimetría o colas, aunque depende de la elección de escala y cantidad de intervalos.
- Gráfico Q–Q: si los residuos son aproximadamente normales, los puntos siguen la recta de referencia. Desvíos sistemáticos, sobre todo en colas, indican discrepancias con la normalidad.
- Residuos en orden temporal: patrones persistentes sugieren dependencia/autocorrelación.
- Residuos estandarizados: residuos expresados en una escala común, ajustada por la variabilidad estimada y el apalancamiento; valores absolutos grandes son señales para investigar, no prueba automática de error.

Guía visual para leer los residuos. Los dibujos son esquemas, no resultados de una muestra. Muestran patrones típicos que conviene buscar en los gráficos diagnósticos:

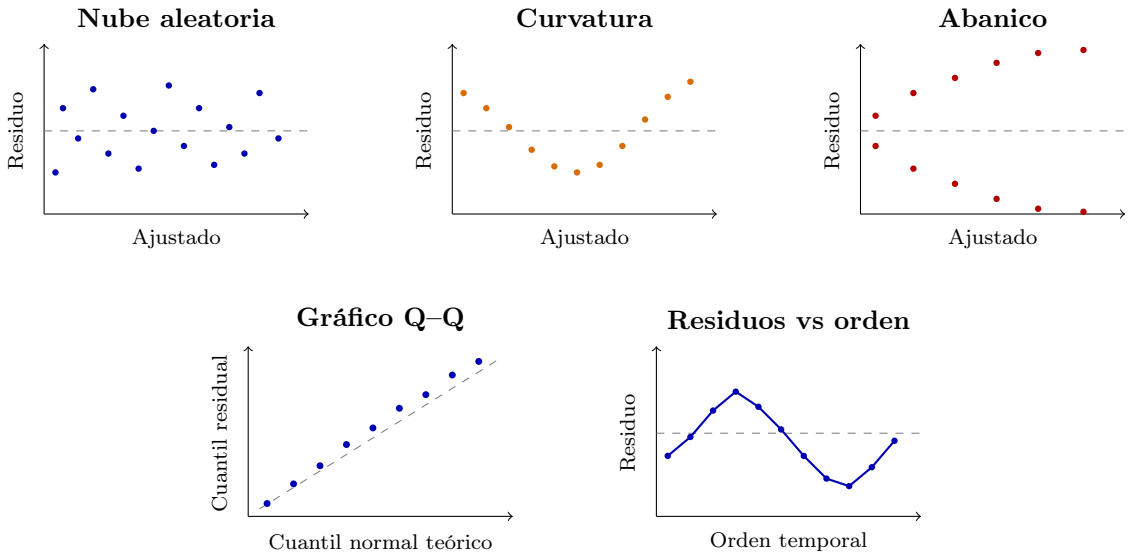


Figura: sin patrón visible es deseable; curvatura sugiere no linealidad, abanico heteroscedasticidad, desvíos del Q–Q no normalidad y rachas temporales posible autocorrelación. Son indicios diagnósticos, no pruebas concluyentes.

Pruebas de normalidad del notebook de repaso: Shapiro–Wilk y Henze–Zirkler (este último para normalidad multivariada) contrastan una hipótesis nula de normalidad univariada o multivariada, según corresponda. Si $p < \alpha$ (usualmente 0,05), se rechaza la hipótesis nula al nivel elegido; si $p \geq \alpha$, no se rechaza, pero eso no prueba normalidad. Con muestras grandes, desviaciones pequeñas pueden producir valores p bajos, por lo que se complementan las pruebas con gráficos.

Precaución específica con Kolmogorov–Smirnov: en el cuaderno se usa `stats.kstest(x, stats.norm.cdf)`, que compara los datos con una normal estándar $N(0, 1)$ completamente especificada.

Las variables `habitaciones` y `dormitorios` son conteos sin estandarizar; tampoco los residuos del ejemplo se transforman previamente en normales estándar. Por eso sus valores p muy pequeños indican discrepancia con $N(0,1)$, pero no constituyen por sí solos una prueba válida de que los datos/residuos no sigan *alguna* distribución normal con media y varianza desconocidas. Para valorar residuos, revisar además histogramas y gráficos Q–Q.

Para una regresión, interesa especialmente diagnosticar la distribución de los **residuos**. Que un predictor por sí solo no sea normal no demuestra que el modelo lineal sea inválido. El notebook ejecuta Henze–Zirkler sobre una muestra simulada de ejemplo, no sobre todos los hogares observados.

3.8. Autocorrelación, influencia y valores atípicos

El estadístico Durbin–Watson suele estar entre 0 y 4. Un valor cercano a 2 es compatible con ausencia de autocorrelación de primer orden; un valor sustancialmente menor que 2 sugiere autocorrelación positiva y uno sustancialmente mayor que 2, negativa. No es una regla de que "debe ser mayor a 2".

Un valor atípico tiene respuesta inusual; un punto de alto apalancamiento tiene predictores inusuales; un punto influyente cambia de manera importante el ajuste si se retira. No son sinónimos. La distancia de Cook combina apalancamiento y residuo para indicar influencia potencial. El umbral $4/n$ es una regla orientativa, no un criterio automático de eliminación.

El notebook de repaso también usa distancia de Mahalanobis para detectar observaciones inusuales en varias variables a la vez. Considera la distancia de una observación al centro teniendo en cuenta escalas y covarianzas entre variables; una distancia cuadrática que supera un umbral basado en χ^2 puede señalar un caso multivariadamente atípico. Detectarlo no autoriza a borrarlo sin revisar errores de datos, contexto y efecto sobre el análisis.

3.9. Inferencia para coeficientes y modelo completo

Para un coeficiente β_j, una prueba usual es $H_0 : \beta_j = 0$ frente a una alternativa, con estadístico t (o z en algunos modelos). La tabla suele mostrar:

- **coef:** estimación del coeficiente;
- **std err:** error estándar, incertidumbre de la estimación;
- **t o z:** estimación medida en errores estándar respecto de la hipótesis nula;
- **P> |t| o P> |z|:** valor p de la prueba;
- **intervalo de confianza:** valores del parámetro compatibles con los datos y el nivel de confianza bajo el modelo.

El valor p es, bajo H_0 y los supuestos del modelo, la probabilidad de observar un estadístico tan extremo como el obtenido o más. Si $p < \alpha$, se rechaza H_0 al nivel elegido; si $p \geq \alpha$, no se rechaza (no equivale a demostrar que sea cierta). Si el intervalo de confianza para el coeficiente no contiene cero, suele ser coherente con significación bilateral al mismo nivel. El valor p no es la probabilidad de que H_0 sea verdadera.

La prueba **t individual** pregunta si un coeficiente particular difiere de cero, dadas las demás variables. La prueba **F global** pregunta si todos los coeficientes de pendiente (excluyendo el intercepto) son simultáneamente cero. En la tabla ANOVA, los grados de libertad son p para regresión, $n - p - 1$ para error y $n - 1$ para el total; el estadístico F compara el cuadrado medio de regresión con el cuadrado

medio residual. Un modelo puede ser globalmente significativo aunque alguno de sus predictores no lo sea.

En regresión lineal simple con intercepto, el contraste de pendiente nula equivale al contraste de correlación poblacional nula. Para la correlación, se plantea $H_0 : \rho = 0$ frente a $H_1 : \rho \neq 0$; bajo H_0, el estadístico habitual es $t = r\sqrt{(n-2)/(1-r^2)}$, con $n-2$ grados de libertad. En ese caso, R^2 coincide con el cuadrado de la correlación muestral de Pearson. Esto no se generaliza sin más a regresión múltiple.

La significación estadística no equivale a importancia práctica: una diferencia diminuta puede ser significativa con gran muestra; una estimación importante puede ser imprecisa. Tampoco demuestra causalidad.

3.10. Intervalos de predicción

Hay dos preguntas distintas para un valor particular $X = x_0$:

- El intervalo de confianza de la media estima la incertidumbre sobre $E(Y \mid X = x_0)$.
- El intervalo de predicción para una observación individual incluye además la variabilidad residual de un nuevo caso y, por eso, es más ancho.

No confundir una predicción puntual con certeza. Ambas bandas suelen ser más estrechas cerca del centro de los valores de X y más amplias lejos de la zona con datos.

3.11. Comparación de modelos

El AIC combina ajuste y penalización por complejidad; en modelos estimados sobre la misma respuesta y datos, un AIC menor favorece el equilibrio entre ajuste y complejidad. No se interpreta como porcentaje ni como una prueba aislada de calidad. Para predicción, el error en validación/test es una evidencia más directa de generalización. No comparar AIC, R^2 o MSE entre respuestas distintas, muestras distintas o escalas no comparables.

3.12. Regresión polinómica y sobreajuste

Un polinomio de grado M puede escribirse como

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \cdots + \beta_M X^M + \varepsilon.$$

Aunque la curva es no lineal en X, el modelo sigue siendo lineal en los coeficientes β_j. El grado M es un hiperparámetro que controla la flexibilidad.

Al aumentar el grado, suele bajar el error de entrenamiento; el error de validación puede bajar y luego subir. Si el modelo sigue detalles accidentales del entrenamiento y predice mal casos nuevos, hay **sobreajuste**. Un grado mayor no significa automáticamente un modelo mejor. La elección debe basarse en datos de validación o validación cruzada; el test se reserva para evaluar la elección final.

3.13. Lectura general de una tabla OLS

En la salida de `statsmodels` de regresión lineal:

- **Dep. Variable / No. Observations:** respuesta y número de casos usados.
- **R-squared / Adj. R-squared:** proporción explicada muestral y versión ajustada.

- **F-statistic / Prob(F-statistic):** contraste global del modelo lineal.
- **coef, std err, t, P> |t|, [0.025, 0.975]:** estimación, incertidumbre, prueba e intervalo de cada parámetro.
- **AIC / BIC:** criterios de ajuste con penalización por complejidad; se comparan en condiciones equivalentes.
- **Durbin–Watson:** diagnóstico de autocorrelación de residuos.
- **Omnibus, Jarque–Bera, Prob(Omnibus), Prob(JB):** indicadores/pruebas relacionados con normalidad de residuos; valores p pequeños sugieren apartamiento de normalidad.
- **Cond. No.:** número de condición; un valor elevado puede alertar sobre escalas muy diferentes o colinealidad, pero requiere diagnóstico adicional.

Si el modelo no incluye intercepto, puede aparecer R^2 "uncentered". No debe compararse sin cuidado con el R^2 ordinario de un modelo con intercepto, porque se calcula de otra manera.

4. Análisis descriptivo y relaciones entre variables

El notebook de repaso contiene análisis exploratorio que ayuda a entender los datos antes de modelar.

- **Media y desviación estándar:** resumen de centro y dispersión sensibles a valores extremos.
- **Mediana y cuartiles:** describen centro y dispersión de manera más resistente. El rango intercuartílico va del primer al tercer cuartil.
- **Histograma:** forma de una distribución univariada; revisar asimetría, multimodalidad y colas.
- **Diagrama de caja:** mediana, cuartiles y valores potencialmente atípicos según una regla gráfica.
- **Diagrama de dispersión:** dirección, forma, agrupamientos, valores atípicos y posible heteroscedasticidad en dos variables.

Correlaciones del notebook:

- **Pearson:** mide intensidad y dirección de asociación lineal entre dos variables cuantitativas; está afectado por valores extremos.
- **Spearman:** correlación de rangos; detecta asociación monótona y no exige que la relación sea recta.
- **Kendall:** mide concordancia de orden entre pares; también se basa en rangos.

Los coeficientes van de -1 a 1: el signo da dirección; la magnitud indica intensidad según la medida. Correlación no implica causalidad. Una relación Pearson baja puede coexistir con una relación no lineal o monótona, razón para observar tanto gráficos como medidas.

5. Clasificación supervisada y análisis discriminante

5.1. Problema de clasificación y regla de decisión

La respuesta Y toma categorías excluyentes, y los predictores X describen a cada observación. La muestra de entrenamiento contiene pares correctamente etiquetados. Los objetivos pueden ser explicar qué variables contribuyen a distinguir grupos o predecir la clase de nuevos casos.

Para clases $g = 1, \ldots, G$, la probabilidad **a priori** π_g representa la proporción/probabilidad previa de la clase. La densidad (o función de masa, si los predictores son discretos) $f_g(x) = f_{X|Y=g}(x)$ describe cómo se distribuyen los predictores dentro de ella. El teorema de Bayes da la probabilidad **a posteriori**:

$$P(Y = g \mid X = x) = \frac{\pi_g f_g(x)}{\sum_{h=1}^{G} \pi_h f_h(x)}.$$

Una regla básica asigna el caso a la clase con mayor probabilidad posterior. Esto presupone costos de error comparables; si falsos positivos y falsos negativos tienen costos distintos, el umbral de decisión puede cambiar.

5.2. Análisis discriminante lineal de Fisher

La función discriminante lineal construye una combinación de predictores,

$$D = u_1 X_1 + u_2 X_2 + \cdots + u_p X_p,$$

que proyecta cada observación en un eje y busca separar las clases. La separación mejora cuando las clases son compactas internamente y sus centros están alejados.

La variación total se descompone en variación **dentro de los grupos** W e **entre los grupos** B: $T = W + B$. La covarianza intraclase combinada (pooled) se estima como $S_p = W/(n - G)$. El criterio de Fisher elige ponderaciones que maximizan una razón del tipo

$$\frac{u^\top B u}{u^\top W u}.$$

En la formulación matricial, las direcciones discriminantes se relacionan con vectores propios de $W^{-1}B$. No es necesario calcularlos a mano para interpretar una salida.

Para dos clases, cada observación recibe una puntuación D_i y se compara con un punto de corte C, usualmente basado en los centroides de las clases. A un lado se asigna una clase y al otro lado la restante. El signo concreto depende de cómo se definieron las clases y la función; siempre revisar la codificación.

Supuesto importante de LDA: las matrices de covarianza de las clases son iguales (homogeneidad intraclase), además de supuestos de distribución aproximadamente normal dentro de cada clase. Si las variabilidades dentro de los grupos son parecidas, la frontera es lineal. Si difieren de manera importante, el análisis discriminante cuadrático (QDA) permite fronteras curvas, con más parámetros. Ambos pueden funcionar bien cuando la separación es razonablemente adecuada; la elección debe considerar supuestos y validación.

Cómo leer coeficientes discriminantes: muestran qué combinación define el eje y en qué dirección empuja cada variable, dados el sentido elegido y la escala. Si las variables tienen escalas muy distintas, las magnitudes brutas no son directamente comparables como medida de importancia. La matriz de coeficientes de clasificación y la de ejes discriminantes pueden además tener interpretaciones/formas distintas según el programa.

6. Evaluación de clasificadores

6.1. Matriz de confusión

Para una clasificación binaria, se define de antemano cuál es la clase positiva (éxito, etiqueta 1). En la convención habitual de la materia y de `sklearn`, las filas son clases reales y las columnas, clases predichas:

	Clase predicha		
Clase real	Positiva (1)	Negativa (0)	Total real
Positiva (P)	Verdadero positivo (VP/TP)	Falso negativo (FN)	$P = VP + FN$
Negativa (N)	Falso positivo (FP)	Verdadero negativo (VN/TN)	$N = FP + VN$
Total predicho	$\widehat{P} = VP + FP$	$\widehat{N} = FN + VN$	$T = P + N$

- **VP/TP:** el caso positivo se detectó correctamente.
- **FN:** el caso era positivo, pero el modelo lo perdió.
- **FP:** el caso era negativo, pero el modelo emitió una falsa alarma.
- **VN/TN:** el caso negativo se reconoció correctamente.

No interpretar una matriz sin comprobar qué eje es real y cuál predicho, qué etiqueta corresponde a cada clase y cuál se definió positiva. La diagonal representa aciertos; las otras celdas, errores.

6.2. Medidas de desempeño

La matriz anterior permite leer rápidamente los denominadores: la suma de la fila positiva es el total de positivos reales; la suma de la fila negativa, el total de negativos reales. Las sumas de columnas son los casos clasificados como positivos o negativos.

Métrica	**Fórmula**	**Pregunta que responde**
Accuracy	$\frac{VP + VN}{T}$	De todos los casos, ¿qué proporción se clasificó correctamente? Puede ocultar fallas en una clase minoritaria.
Error	$\frac{FP + FN}{T} = 1 - \text{Accuracy}$	¿Qué proporción total quedó mal clasificada?
Sensibilidad / recall (TPR)	$\frac{VP}{VP + FN}$	De los positivos reales, ¿qué proporción detectó? Un valor bajo implica muchos falsos negativos.
Especificidad TNR	$\frac{VN}{VN + FP}$	De los negativos reales, ¿qué proporción reconoció correctamente? Un valor bajo implica muchos falsos positivos.
Precisión / PPV	$\frac{VP}{VP + FP}$	De los casos predichos positivos, ¿qué proporción realmente era positiva?
Valor predictivo negativo / NPV	$\frac{VN}{VN + FN}$	De los casos predichos negativos, ¿qué proporción realmente era negativa?
F1	$2\frac{PPV \cdot \text{Recall}}{PPV + \text{Recall}}$	Media armónica de precisión y recall; los resume, pero no incorpora directamente los verdaderos negativos.

La sensibilidad y especificidad condicionan en la clase real; precisión y NPV condicionan en la predicción. Por eso no son intercambiables. Las medidas predictivas (PPV y NPV) también dependen de la prevalencia de la clase positiva en la población. En `classification_report`, **support** es la cantidad de casos reales de cada clase; **macro avg** promedia las métricas de las clases dándoles igual peso, y **weighted avg** las promedia ponderando por support, por lo que las clases más frecuentes influyen más. Un promedio ponderado alto puede ocultar un resultado débil en la clase minoritaria.

6.3. Desbalance de clases, sobremuestreo y SMOTE

Hay **desbalance** cuando una clase aparece mucho más que otra. Un clasificador que siempre predice la clase mayoritaria puede obtener un accuracy alto y, a la vez, no detectar ningún caso de la clase minoritaria. Por eso se debe mirar la matriz de confusión y las métricas relevantes para cada clase, en particular sensibilidad/recall, especificidad y precisión.

El **sobremuestreo** aumenta la representación de la clase minoritaria durante el entrenamiento. SMOTE (*Synthetic Minority Over-sampling Technique*) crea observaciones sintéticas interpolando entre casos minoritarios cercanos; no equivale a recolectar nuevos casos reales ni simplemente a duplicar cada observación. Con predictores discretos, una interpolación puede incluso producir valores fraccionarios que no representen casos observables.

Balancear los datos de entrenamiento puede ayudar a aprender la clase rara, pero no cambia la prevalencia real de la población. Si se evalúa sobre una muestra artificialmente balanceada, el accuracy, la precisión (PPV), el NPV y la interpretación de la probabilidad predicha no representan directamente el desempeño a la prevalencia original. La sensibilidad y la especificidad no dependen algebraicamente de la prevalencia, aunque sí pueden variar si cambia la población o la distribución de los casos. La evaluación final conviene hacerla sobre datos no remuestreados que conserven la prevalencia de interés.

Para evitar **fuga de información**, primero se separan los datos de entrenamiento y evaluación; SMOTE se aplica solo al entrenamiento. En validación cruzada, la generación de sintéticos debe ocurrir dentro de cada pliegue de entrenamiento, nunca antes de dividir todos los datos en pliegues: de otro modo, las observaciones usadas para validar pueden influir en los sintéticos del entrenamiento. Como SMOTE busca vecinos mediante distancias, también es sensible a las escalas: una variable de magnitud mucho mayor puede dominar qué observaciones se consideran cercanas. El escalado, si corresponde, se ajusta solo con los datos de entrenamiento y antes de aplicar SMOTE.

6.4. Umbral de clasificación y curva ROC

La logística suele producir una probabilidad estimada $\widehat{p}$. Con umbral c, se predice positivo si $\widehat{p} \geq c$ y negativo si $\widehat{p} < c$. Un umbral de 0,5 es común, no universalmente óptimo.

Si se baja el umbral, habitualmente se detectan más positivos: aumenta sensibilidad, pero puede aumentar FP y bajar especificidad. Si se sube, suele disminuir la sensibilidad y aumentar la especificidad. La elección depende del costo de cada tipo de error.

La curva ROC muestra TPR/sensibilidad en el eje vertical frente a FPR, donde FPR $= 1 -$ especificidad, en el eje horizontal, al recorrer umbrales. Aunque algunas diapositivas la describen como sensibilidad frente a especificidad, la convención gráfica más frecuente usa tasa de falsos positivos ($1-$ especificidad). Una curva más cerca de la esquina superior izquierda suele ser mejor.

El AUC es el área bajo ROC: resume la capacidad de ordenar positivos por encima de negativos a través de umbrales. 0,5 equivale aproximadamente a discriminación aleatoria; 1 es discriminación perfecta. AUC no indica que un umbral específico sea adecuado, ni reemplaza la revisión de sensibilidad/especificidad y del costo de errores.

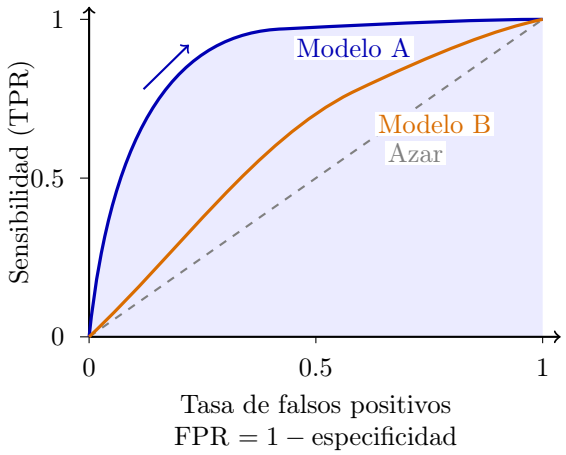


Figura: esquema ROC. Curvas más próximas a la esquina superior izquierda discriminan mejor; el área sombreada ilustra el AUC de una curva, no un umbral particular. La flecha representa el desplazamiento habitual al bajar el umbral.

La guía de rangos usada en las diapositivas es orientativa, no una escala universal:

AUC	**Lectura aproximada**
0,50	Rendimiento equivalente al azar
0,50–0,60	Bajo
0,60–0,75	Regular
0,75–0,90	Bueno
0,90–0,97	Muy bueno
0,97–1,00	Excelente; 1 corresponde a separación perfecta

Las bandas dependen del contexto y no reemplazan la evaluación con costos, prevalencia y umbral de decisión. En particular, dos modelos con AUC similar pueden tener sensibilidad y especificidad distintas en el umbral de interés.

6.5. Validación: tasa aparente, holdout y validación cruzada

La **tasa aparente** evalúa los casos usados para ajustar el modelo y suele ser demasiado optimista. En **holdout**, una parte de los datos entrena y otra, no usada para ajustar, evalúa. En validación cruzada de k pliegues, los datos se dividen en k partes; se ajusta repetidamente con $k-1$ partes y se evalúa en la restante. Se promedian los resultados. Valores frecuentes de k son 5 o 10.

La validación cruzada ayuda a comparar modelos de forma más estable, pero no convierte los datos usados en test final. Si se prueban muchas configuraciones, se elige con validación y se guarda un conjunto test para una evaluación final. Calcular predicciones sobre los mismos datos usados para ajustar mide desempeño aparente, aunque el notebook lo nombre “test”.

7. Regresión logística binaria

7.1. Por qué no usar regresión lineal para una respuesta binaria

Si Y solo puede valer 0 o 1, la regresión lineal puede producir predicciones fuera del rango de probabilidades $[0,1]$. Además, la distribución de la respuesta condicionada en X es Bernoulli, con varianza que

depende de la probabilidad; no cumple el modelo lineal clásico de errores normales y varianza constante. La regresión logística modela directamente la probabilidad y la mantiene entre 0 y 1.

7.2. Probabilidad, odds y logit

Para $Y \in \{0, 1\}$, la regresión logística modela

$$p(x) = P(Y = 1 \mid X = x) = \frac{1}{1 + \exp[-(\beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p)]}.$$

La función logística transforma cualquier combinación lineal en una probabilidad entre 0 y 1. El predictor lineal no es la probabilidad: es el logaritmo de las odds.

$$\text{odds} = \frac{p}{1-p}, \qquad \log\left(\frac{p}{1-p}\right) = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p.$$

Las **odds** comparan probabilidad de ocurrencia con probabilidad de no ocurrencia; no son lo mismo que la probabilidad ni que un riesgo relativo.

7.3. Interpretación de coeficientes y odds ratio

En una regresión logística, β_j es el cambio en el logaritmo de las odds por un aumento de una unidad en X_j, manteniendo fijas las demás variables. Al exponenciarlo,

$$\text{OR}_j = \exp(\beta_j)$$

se obtiene el multiplicador de las odds ante ese aumento unitario.

- OR $= 1$: las odds no cambian por esa unidad.
- OR > 1: las odds aumentan. Por ejemplo, OR $= 2$ significa odds dos veces mayores, es decir, un aumento del 100 % en las odds.
- OR < 1: las odds disminuyen. Por ejemplo, OR $= 0{,}60$ significa odds 0.60 veces las anteriores, aproximadamente 40 % menores.

El OR no significa que la probabilidad se multiplique por ese valor. La variación de probabilidad depende del nivel inicial de probabilidad. Una misma pendiente logística puede tener cambios de probabilidad distintos según el caso.

Para una variable categórica, interpretar el OR frente a la categoría de referencia y según cómo esté codificada. Para un predictor continuo, precisar que el cambio es por una unidad y, si las unidades lo exigen, explicar una variación más útil (por ejemplo, 10 unidades). Mantener las demás variables constantes.

El riesgo relativo compara probabilidades de ocurrencia entre grupos; el odds ratio compara odds. Se parecen cuando el evento es poco frecuente, pero pueden diferir bastante cuando no lo es.

7.4. Estimación y pruebas de hipótesis

Los coeficientes logísticos se estiman usualmente por máxima verosimilitud. En una salida de `statsmodels`:

- **coef:** efecto sobre log-odds, no sobre la probabilidad directamente.
- **std err, z, P> |z|:** incertidumbre y prueba de $H_0 : \beta_j = 0$. Una alternativa equivalente en OR es $H_0 : \mathrm{OR}_j = 1$.
- **[0.025, 0.975]:** intervalo para el coeficiente. Si se exponentian los extremos, el intervalo del OR no contiene 1 cuando el correspondiente coeficiente no contiene 0.
- **Log-Likelihood y LL-Null:** verosimilitud del modelo con predictores y del modelo nulo con solo intercepto.
- **LLR p-value:** prueba de razón de verosimilitudes para comparar el modelo completo con el nulo. Un valor pequeño indica evidencia de que el conjunto de predictores mejora el modelo nulo.
- **Pseudo R-squared:** medida comparativa basada en verosimilitud. No se interpreta como el porcentaje de varianza explicada del R^2 lineal.

La prueba global de razón de verosimilitudes y las pruebas individuales de Wald responden preguntas distintas. Un modelo globalmente significativo puede contener predictores no significativos.

La separación completa o cuasi completa ocurre cuando una combinación de predictores clasifica perfectamente o casi perfectamente una parte de los datos. Puede causar estimaciones inestables o parámetros no identificables; tomar con cautela coeficientes, errores estándar y valores p cuando el resumen muestra esa advertencia.

7.5. Logística predictiva y logística explicativa

En los notebooks, `statsmodels` se usa para obtener resumen inferencial: coeficientes, pruebas e intervalos. `scikit-learn` se utiliza sobre todo para predicción, validación y métricas. Por defecto, la logística de scikit-learn aplica regularización; sus coeficientes no se deben tratar como si fueran directamente la misma estimación MCO o el mismo ajuste de máxima verosimilitud sin penalización de una tabla inferencial.

La regularización limita coeficientes para controlar complejidad. En el notebook 9, C es inverso de la intensidad de regularización: C menor implica penalización más fuerte y C mayor, más débil. El solver es el procedimiento de optimización; no tiene interpretación sustantiva. `class_weight=balanced` da mayor peso a clases menos frecuentes; puede mejorar la detección de la clase minoritaria, a menudo a costa de más falsos positivos.

8. Ejemplos de lectura de los notebooks

Los valores que siguen ilustran cómo traducir salidas a conclusiones. Su finalidad es practicar lectura; no son resultados universales ni evidencia causal.

8.1. Cuaderno 6: simple, polinómica y múltiple

Regresión simple de consumo sobre ingresos. El notebook informa pendiente cercana a 0,916, MSE de prueba cercano a $3{,}53 \times 10^9$ y R^2 de prueba igual a 0,05. La pendiente describe una asociación lineal positiva: un aumento unitario de ingresos se relaciona con cerca de 0.916 unidades de consumo ajustado. El R^2 bajo indica que el modelo lineal simple explica poca variación del consumo en esa evaluación. El MSE debe contextualizarse en la escala del consumo.

Regresión múltiple de consumo. Se incluyen ingresos, endeudamiento, antigüedad de préstamo, edad y sexo. El MSE de prueba informado es aproximadamente $3{,}46 \times 10^9$. Se reportan además MAE

$\approx$ 42067, RMSE $\approx$ 58784 y RMSLE $\approx$ 1,219. RMSE está en unidades de consumo; MAE es el error absoluto promedio. No se puede inferir significación de coeficientes de esa salida de scikit-learn, porque la métrica predictiva no es una prueba individual.

Advertencia importante sobre la comparación del cuaderno. El código del modelo polinómico define como predictor el consumo y como respuesta los ingresos, pero la regresión simple y la múltiple predicen consumo a partir de ingresos/otras variables. Por eso el MSE polinómico informado ($\approx 5{,}20 \times 10^8$) no se debe comparar directamente con los MSE de los otros modelos: cambia la variable respuesta y su escala. Además, el grado 5 elegido mediante validación describe una curva flexible, no prueba que sea el mejor modelo en una comparación homogénea con esas otras salidas. Antes de comparar métricas, comprobar siempre qué predice cada modelo.

8.2. Cuaderno 7: correlación y regresión OLS

Dormitorios según habitaciones. El ajuste lineal simple informa intercepto $\approx$ 0,697 y pendiente $\approx$ 0,379. En el modelo ajustado, una habitación adicional se asocia con unos 0.379 dormitorios más en promedio. No significa que cada vivienda tenga esa fracción de dormitorio ni que agregar una habitación cause el cambio.

Ingreso laboral según horas y edad. La salida múltiple informa $R^2 \approx 0{,}115$, prueba global F con valor p prácticamente cero, y coeficientes aproximados de 762 para horas trabajadas y 468 para edad, ambos con valores p pequeños. Interpretación: controlando por edad, una unidad adicional de horas se asocia con 762 unidades más de ingreso ajustado; controlando por horas, una unidad adicional de edad con 468 unidades más. El intercepto no resulta significativo ($p \approx 0{,}324$) y R^2 indica ajuste explicativo modesto aunque el modelo sea globalmente significativo. La gran cantidad de observaciones contribuye a detectar asociaciones pequeñas.

Categoría género. Al incluir una variable categórica, la salida presenta `x3[T.Varon]` como contraste frente a Mujer. El coeficiente es aproximadamente 4371 y su valor p es pequeño: en ese modelo, varones tienen mayor ingreso ajustado que mujeres con horas y edad iguales. No convertirlo en afirmación causal ni ignorar potenciales variables omitidas.

Normalidad y autocorrelación. El modelo múltiple de ingreso muestra Durbin–Watson $\approx$ 1,603, compatible con posible autocorrelación positiva según la regla orientativa. Omnibus/Jarque–Bera tienen valores p muy pequeños, lo que sugiere residuos no normales bajo esas pruebas. Para datos transversales, el orden de las filas puede no representar una secuencia temporal real, así que el valor Durbin–Watson debe contextualizarse. El Kolmogorov–Smirnov de otro ajuste arroja un p diminuto, pero compara los residuos sin estandarizar con $N(0, 1)$; no debe interpretarse como prueba de no normalidad general. Para el alcance de esta guía, priorizar la lectura conjunta de las pruebas adecuadas y de los gráficos de residuos.

8.3. Repaso discriminante y logístico: regresión y residuos

En la regresión simple que predice el ITF del hogar a partir de habitaciones, el cuaderno calcula el error de prueba como $y_{\text{test}} - \widehat{y}_{\text{test}}$ y lo grafica frente a los valores predichos. La nube se abre en abanico; el histograma presenta asimetría a la derecha; y el gráfico observado–predicho forma una banda horizontal en vez de concentrarse alrededor de la diagonal. En conjunto, sugieren varianza no constante y que un único predictor no representa bien las diferencias de ingreso.

El cuaderno cuantifica el abanico agrupando por nivel predicho: la desviación estándar del error pasa de aproximadamente 42.125 pesos en el tramo bajo a 88.558 pesos en el alto, unas 2.1 veces más. Son errores de predicción del conjunto de prueba, útiles para revisar cómo varía el desempeño, no una prueba

formal de hipótesis. La lectura clave es complementar las métricas globales con los gráficos: el modelo es más impreciso para hogares con predicciones altas.

8.4. Cuaderno 8: pobreza, odds y métricas

Odds ratio frente a significación. En la logística de pobreza, el modelo inicial usa 1066 hogares. Informa pseudo-$R^2 \approx 0{,}857$ y LLR p-value muy pequeño: el conjunto de predictores mejora claramente al modelo nulo en esa muestra. En la tabla de coeficientes, Jef_Educ tiene $p \approx 0{,}310$ y no es significativa al 5 %; Jef_EC, Jef_Edad, DECIL y Cant_Miembros sí muestran valores p pequeños en ese ajuste. El modelo también advierte cuasi-separación, por lo que la aparente calidad muy alta y las estimaciones requieren cautela.

En el segundo modelo, el coeficiente de DECIL es cercano a $-3{,}57$ y su OR es $\exp(-3{,}57) \approx 0{,}028$. Si el decil está codificado numéricamente y la especificación es adecuada, cada incremento de un decil multiplica las odds ajustadas de pobreza por aproximadamente 0.028. No significa que la probabilidad disminuya exactamente ese porcentaje; tampoco es una comparación categórica libre si se codificó como número.

Problema de la actividad de razón de riesgos. El texto de la actividad pide comparar el riesgo de pobreza según exposición a NBI, pero la llamada del código especifica Pobre como exposición y NBI_TOTAL como resultado. La salida cercana a 9.996 corresponde a esa orientación invertida: riesgo de NBI según pobreza, no directamente riesgo de pobreza según NBI. Además, el procedimiento usado es RiskRatio, por lo que se trata de una razón de riesgos, no de un odds ratio; la hipótesis nula del cociente igual a 1 aplica a ambas medidas, pero deben nombrarse correctamente. Para contestar la actividad tal como está formulada hay que confirmar/cambiar cuál variable es exposición y cuál resultado.

Predicciones y umbral. Valores predichos como 0.9 son probabilidades estimadas de pobreza, no clases seguras. Al usar umbral 0.5, 0.9 se clasifica como positivo y 0.3 como negativo. Cambiar el umbral modifica los conteos de falsos positivos y falsos negativos.

Concordancia y matriz de confusión. El notebook informa exactitud aproximada de 96.44 %, sensibilidad 91.74 % y especificidad 97.73 %. Esas medidas se calculan prediciendo en el mismo conjunto de hogares usado para estimar el modelo, no en un holdout independiente. Por lo tanto, son tasas aparentes y probablemente optimistas. A partir del tamaño de clases y las tasas informadas, la matriz corresponde aproximadamente a VN=817, FP=19, FN=19 y VP=211.

8.5. Cuaderno 8: discriminante lineal

En la base de 26 países, la matriz de confusión es $\begin{pmatrix} 12 & 1 \\ 2 & 11 \end{pmatrix}$, con filas reales y columnas predichas. El modelo clasifica correctamente 23 de 26 casos, exactitud $\approx 88{,}5\,\%$. Para clase 0, recall es 0.923; para clase 1, 0.846. Esta es una tasa aparente: el notebook ajusta y predice sobre los mismos 26 países. El desempeño real en nuevos países podría ser menor.

Los coeficientes definen una dirección discriminante y su combinación produce una puntuación; su signo aislado no se interpreta como efecto causal. Las variables tienen escalas distintas y la muestra es pequeña, así que no tomar los coeficientes brutos como una clasificación fiable fuera de esa muestra.

8.6. Cuaderno 9: clasificación de clientes bancarios

La respuesta es tenencia de tarjeta Visa ($TV = 1$ frente a $TV = 0$). El notebook separa entrenamiento y test, con estratificación para conservar aproximadamente la proporción de clases. En la salida base, la

matriz de test es

$$\begin{pmatrix} 252 & 52 \\ 72 & 122 \end{pmatrix},$$

con 0,751 de accuracy. Para la clase 1, la sensibilidad/recall es $122/(122+72) \approx 0{,}629$; la especificidad para clase 0 es $252/(252+52) \approx 0{,}829$. El modelo reconoce mejor los negativos que los positivos con ese umbral.

La búsqueda en validación cruzada selecciona $C = 10$ y solver liblinear, con accuracy medio cercano a 0.782. La tabla de test del ajuste posterior da

$$\begin{pmatrix} 254 & 50 \\ 61 & 133 \end{pmatrix},$$

accuracy $\approx 0{,}777$, recall de clase 1 $\approx 0{,}69$, precisión de clase 1 $\approx 0{,}73$ y F1 de clase 1 $\approx 0{,}71$. La precisión responde qué proporción de los predichos como 1 realmente son 1; el recall responde qué proporción de todos los 1 reales se detectó; F1 resume precisión y recall en una sola medida.

Con `class_weight=balanced`, el notebook informa

$$\begin{pmatrix} 227 & 77 \\ 34 & 160 \end{pmatrix}.$$

La sensibilidad de clase 1 sube a $160/(160+34) \approx 0{,}825$, pero la especificidad baja a $227/(227+77) \approx 0{,}747$: se detectan más clientes positivos, a costa de más falsos positivos. El accuracy queda alrededor de 0.777. Qué opción conviene depende del costo relativo de ambos errores, no solo de cuál tiene mayor cifra de accuracy.

Lectura de la salida logística inferencial. El modelo de `statsmodels` informa pseudo-$R^2 \approx 0{,}289$ y LLR p-value muy pequeño; el conjunto de predictores mejora al modelo nulo. Edad, estado civil y antigüedad en préstamos tienen valores p mayores a 0.05 en la tabla y no son significativos al nivel usual. Sexo sí tiene coeficiente cercano a $-0{,}520$ con $p < 0{,}001$; su OR es $\exp(-0{,}520) \approx 0{,}595$ por incremento unitario de la codificación. El cuaderno codifica Sexo como 1=varón y 2=mujer: condicionalmente a los demás predictores, el código 2 tiene odds estimadas de tenencia de Visa aproximadamente 40 % menores que el código 1; sigue siendo una asociación ajustada, no causal. La nota escrita del notebook dice que Sexo no es significativo, pero contradice su propia tabla; para interpretar, debe prevalecer la tabla numérica. Como Sexo y estado civil se incorporan con códigos numéricos (1/2 y 1/2/3), el modelo trata sus códigos como ordenados y presupone el mismo cambio en log-odds por cada paso.

La nota de selección de hiperparámetros del notebook también contiene una discrepancia: la salida de la búsqueda informa $C = 10$, mientras que una frase posterior menciona 1.0. Leer el resultado impreso antes que el texto incongruente.

Además, la búsqueda de hiperparámetros usa una tubería con estandarización y regresión logística, mientras que el ajuste posterior que produce la matriz de test vuelve a estimar una regresión logística sin estandarizar los predictores. Por ello, la accuracy promedio de validación cruzada ($\approx 0{,}782$) y las métricas de test ($\approx 0{,}777$) no corresponden exactamente al mismo procedimiento; no presentarlas como la evaluación entrenamiento/test de un único pipeline sin esta salvedad.

8.7. Clase 12: SMOTE, LDA, logística y curva ROC

El cuaderno usa una muestra de la EPH de Gran Córdoba del segundo trimestre de 2018, con 1413 personas. La respuesta es `Desocupado`: hay 1309 casos con etiqueta 0 y 104 con etiqueta 1 (aproximadamente 92.6 % y 7.4 %, respectivamente). Los predictores seleccionados son `Edad`, `IT_MIEMBRO` y `Cant_Miembros`.

En los datos originales, predecir siempre la clase 0 ya daría 92.6 % de accuracy, pero sensibilidad cero para la clase 1: un ejemplo claro de por qué el accuracy aislado puede ocultar el problema importante.

El cuaderno aplica SMOTE a la base completa antes de la validación cruzada. El resultado tiene 1309 casos por clase (2618 en total), incluidos casos sintéticos de la clase 1. Esto facilita comparar métricas por clase en esa muestra balanceada, pero la deja con una prevalencia artificial. Más importante aún, el remuestreo previo a los pliegues produce fuga de información: los datos de validación pueden haber influido en los vecinos y sintéticos usados para entrenar. Por eso las tasas que siguen son ilustrativas para leer salidas, no una estimación confiable del desempeño en personas nuevas. El cuaderno también deja comentado el escalado previo a SMOTE; como las tres variables están en escalas muy distintas, la variable de mayor escala puede dominar la búsqueda de vecinos y afectar qué sintéticos se generan.

En las salidas de `sklearn`, la matriz de confusión usa por defecto el orden de etiquetas 0 y 1, con filas reales y columnas predichas. Por ello, si la clase positiva es 1, la disposición de sus celdas es TN, FP en la primera fila y FN, TP en la segunda (distinta del esquema positivo-primero usado arriba).

Modelo	Matriz orden 0,1	Sensibilidad clase 1	Especificidad clase 0	Accuracy
LDA	$\begin{pmatrix} 965 & 344 \\ 88 & 1221 \end{pmatrix}$	0.933	0.737	0.835
Logística	$\begin{pmatrix} 1120 & 189 \\ 153 & 1156 \end{pmatrix}$	0.883	0.856	0.869

Interpretación. El LDA detecta 1221 de 1309 positivos: sensibilidad $\approx 0{,}933$, pero su especificidad es $965/(965+344) \approx 0{,}737$ porque clasifica 344 negativos como positivos. La logística detecta 1156 de 1309 positivos: sensibilidad $\approx 0{,}883$ y especificidad $1120/(1120+189) \approx 0{,}856$. En esta salida, logística tiene mayor accuracy y especificidad, mientras que LDA tiene mayor sensibilidad: la elección depende del costo de falsos negativos frente a falsas alarmas. La precisión/F1 de clase 1 son, respectivamente, 0,780/0,850 para LDA y 0,859/0,871 para logística.

El `support` de 1309 para cada clase en ambos reportes corresponde a la base remuestreada, no a la muestra original, donde solo había 104 casos de clase 1. Además, las matrices proceden de `cross_val_predict` (cinco pliegues por defecto), mientras que el cuaderno informa `cross_val_score` con 10 pliegues para LDA y 5 para logística. No confundir esas salidas como si fueran exactamente el mismo resumen de validación. La etiqueta escrita en el notebook que llama a la tasa una "verdadera tasa" tampoco la convierte en desempeño poblacional: sigue siendo una evaluación afectada por el remuestreo previo.

Coeficientes LDA. Los coeficientes son pesos de una función discriminante, no efectos causales ni pruebas de significación. En el cuaderno se imprimen redondeados a seis decimales y algunos aparecen como $-0{,}0$; eso no prueba que la variable tenga efecto exactamente nulo. Tampoco deben compararse directamente como importancia si los predictores están en escalas diferentes. La salida `scalings_` corresponde a otra representación de la dirección discriminante; su lectura depende de la parametrización y el escalado.

Advertencia sobre la ROC del cuaderno. El cálculo pasa a `roc_curve` las etiquetas predichas 0/1 de cada modelo, no probabilidades estimadas ni puntuaciones discriminantes continuas. Así solo se obtiene el punto de operación de ese umbral junto con los extremos de la curva; no se compara el comportamiento a través de todos los umbrales como en una ROC construida con puntuaciones. En esta base balanceada, el AUC obtenido de etiquetas duras coincide con el promedio de los recalls de ambas clases (accuracy balanceado), aproximadamente 0.835 para LDA y 0.869 para logística. Para evaluar discriminación a distintos umbrales se necesitan probabilidades o puntuaciones continuas calculadas en datos de evaluación adecuados.

8.8. Repaso discriminante y logístico: evaluación de pobreza

Con hogares de la EPH del cuarto trimestre de 2021, este cuaderno construye una respuesta didáctica: $Y = 1$ si el ingreso familiar per cápita queda por debajo de 25.000 pesos mensuales. No es la medición oficial de pobreza del INDEC. En la base hay 7.793 hogares sobre el umbral y 5.654 por debajo (42 % positivos). El modelo logístico usa cantidad de integrantes, habitaciones y dormitorios; la partición estratificada reserva 30 % para prueba y conserva aproximadamente la prevalencia de clases. En el conjunto de prueba hay 4.035 hogares: 2.338 sobre el umbral y 1.697 debajo.

Gráfico y tabla de odds ratios. El cuaderno muestra los OR en escala logarítmica, con una línea vertical en 1: a un lado quedan los multiplicadores de odds menores que 1 y al otro los mayores que 1. La salida estimada se resume así:

Predictor	$\widehat{\beta}$	**OR**	**Lectura por unidad adicional**
Integrantes del hogar	0.79	2.206	Las odds estimadas de estar bajo el umbral se multiplican por 2.206 (aumentan 120.6 %).
Habitaciones	−0,47	0.627	Las odds estimadas se multiplican por 0.627 (disminuyen 37.3 %).
Dormitorios	0.12	1.130	Las odds estimadas se multiplican por 1.130 (aumentan 13.0 %).

Son asociaciones ajustadas por los demás predictores, no cambios directos en probabilidad ni efectos causales. Además, este ajuste de `scikit-learn` no presenta pruebas p o intervalos para estos coeficientes: no atribuirles significación estadística a partir del gráfico de OR. Los aumentos o reducciones porcentuales se refieren a las *odds*, no a la probabilidad.

Matriz de confusión al umbral 0.5. La clase positiva es "bajo el umbral". Las filas corresponden a la condición real y las columnas a la predicción; por lo tanto, el FN son hogares bajo el umbral que el modelo no detecta y el FP son hogares sobre el umbral marcados como positivos:

	Predicho: sobre umbral	Predicho: bajo umbral
Real: sobre umbral	**VN** 1.875	**FP** 463
Real: bajo umbral	**FN** 660	**VP** 1.037

Figura: verde = clasificación correcta; rojo = error. Se leen filas reales y columnas predichas.

La salida informa accuracy de 72.2 %, precisión de 69.1 %, sensibilidad de 61.1 %, especificidad de 80.2 % y $F_1 = 64{,}9\,\%$. El clasificador trivial que predice siempre la clase mayoritaria alcanza 57.9 % de accuracy en esta prueba; el modelo mejora esa referencia en 14.2 puntos porcentuales, pero aun así deja sin detectar 660 de los 1.697 hogares positivos (38.9 %). Por eso la accuracy no basta para juzgar si el modelo es adecuado.

ROC y AUC. A diferencia del cálculo de Clase 12, que usó etiquetas duras 0/1 y por eso no informa la discriminación del modelo a través de sus umbrales, aquí `roc_curve` recibe las probabilidades estimadas en el conjunto de prueba. El AUC informado es 0.775: si se toma al azar un hogar positivo y uno negativo, el modelo asigna una puntuación mayor al positivo en aproximadamente 77.5 % de los pares (con la convención habitual para empates). En el gráfico, la diagonal es la referencia de azar y el punto marcado para el umbral 0.5 corresponde a sensibilidad 61.1 % y FPR = 1 − especificidad = 19,8 %. El panel de histogramas superpone las probabilidades estimadas para ambas clases: cuanto mayor es

el solapamiento, más difíciles son de separar. El AUC resume discriminación entre umbrales, no la exactitud en el corte 0.5, no garantiza probabilidades bien calibradas y no decide el corte. El cuaderno llama "aceptable" a un AUC entre 0.7 y 0.8; estas etiquetas cualitativas son orientativas y varían entre materiales, por lo que conviene priorizar el valor y su interpretación, no una categoría universal.

Comparación de umbrales. Las tres opciones usan el mismo modelo y sus mismas probabilidades: únicamente cambia la clasificación final. Los conteos siguientes son del conjunto de prueba, no totales poblacionales ni hogares que efectivamente recibieron asistencia.

Umbral	FN: pobres no detectados	FP: no pobres marcados	Marcados positivos	Sensibilidad	Precisión
0.30	324	1.028	2.401	80.9 %	57.2 %
0.50	660	463	1.500	61.1 %	69.1 %
0.70	1.065	135	767	37.2 %	82.4 %

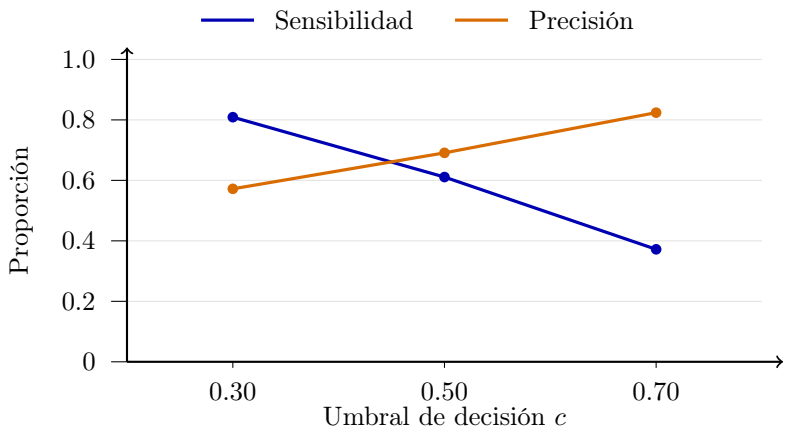


Figura: sensibilidad y precisión en los tres umbrales del cuaderno; los segmentos solo guían la lectura y no muestran todos los cortes posibles.

Al bajar el corte a 0.30 se detectan más hogares pobres, pero aumentan las falsas alarmas; al subirlo a 0.70 se reducen los falsos positivos, pero quedan muchos más hogares pobres sin detectar. El umbral 0.5 es una convención, no una decisión universal que garantice costos iguales. La elección depende de los costos y objetivos del uso, y corresponde justificarla explícitamente.

Límite de la comparación. El cuaderno calcula también métricas y un umbral con mejor F_1 sobre este mismo conjunto de prueba. Como demostración del intercambio entre umbrales es útil; pero si se usa la prueba para elegir el umbral, deja de ser una evaluación final independiente. Para informar desempeño sin sesgo de selección, el umbral se elige con entrenamiento/validación o validación cruzada y se evalúa una sola vez en un test que permanezca intacto.

9. Errores frecuentes y cómo evitarlos

1. Decir que un coeficiente logístico es un cambio directo en probabilidad. Es cambio en log-odds; exponenciado, es un multiplicador de odds.
2. Llamar "riesgo relativo" al OR o viceversa. Revisar qué cociente se estimó.
3. Interpretar significación global como significación de todos los coeficientes. Revisar cada valor p individual.

4. Decir que un valor p pequeño mide el tamaño o la importancia del efecto. Informa incompatibilidad de los datos con una hipótesis nula bajo supuestos.
5. Tratar R^2 como porcentaje de aciertos o como causalidad. Es proporción de variación ajustada en regresión lineal con intercepto.
6. Comparar MSE de respuestas, muestras o escalas diferentes. Primero comprobar la variable dependiente y la partición de evaluación.
7. Llamar test a la tasa calculada sobre los mismos datos usados para entrenar. Es tasa aparente.
8. Informar accuracy cuando hay desbalance sin mirar sensibilidad, especificidad y matriz de confusión.
9. Ignorar la codificación de positivo, categorías y referencia. La interpretación cambia con las etiquetas.
10. Interpretar correlación o regresión observacional como causalidad.
11. Decir que no rechazar normalidad prueba normalidad, o que un predictor no normal invalida automáticamente OLS.
12. Eliminar automáticamente valores atípicos o puntos influyentes sin investigación.
13. Afirmar que Durbin–Watson "debe ser mayor que 2". Cerca de 2 es lo esperado sin autocorrelación; menor sugiere positiva y mayor, negativa.
14. Aplicar SMOTE antes de separar entrenamiento y prueba o antes de crear pliegues de validación cruzada. Esto puede filtrar información de evaluación al entrenamiento.
15. Interpretar como ROC completa una curva calculada con etiquetas 0/1. Para recorrer umbrales se requieren probabilidades o puntuaciones continuas.

10. Preguntas de práctica con respuestas modelo

1. **Una salida muestra $R^2 = 0{,}05$. ¿Qué se concluye?** En el ajuste de entrenamiento con intercepto, representa aproximadamente un 5 % de variación explicada; en test, equivale a una reducción cercana al 5 % del error cuadrático frente al predictor de referencia basado en la media de test. En ambos casos el ajuste es modesto: no indica 5 % de aciertos ni demuestra causalidad.
2. **Un predictor tiene coeficiente positivo y $p = 0{,}20$. ¿Es un efecto demostrado?** No. La estimación apunta a asociación positiva, pero no se rechaza $H_0 : \beta = 0$ al 5 %. Revisar intervalo y precisión; no significación no prueba que el efecto sea exactamente cero.
3. **El modelo logístico tiene $\beta = -0{,}7$. ¿Cómo se interpreta?** Por unidad adicional del predictor, las log-odds bajan 0.7, controlando por los demás. Las odds se multiplican por $e^{-0{,}7} \approx 0{,}50$, cerca de la mitad; no se afirma que la probabilidad se reduzca a la mitad.
4. **La matriz tiene FN altos. ¿Qué falla?** Se están escapando muchos positivos reales; la sensibilidad es baja. Puede considerarse un umbral menor si es importante detectar positivos, aceptando que quizá aumenten falsos positivos.
5. **La sensibilidad es alta y la especificidad baja. ¿Qué significa?** El modelo detecta una fracción grande de positivos reales pero clasifica como positivos algunos negativos reales. Evaluar el costo relativo de cada error.
6. **El ROC tiene AUC 0.90. ¿Qué informa?** Buena capacidad de discriminación/ranking entre clases a través de umbrales; no determina por sí sola el umbral de operación ni garantiza buena calibración de probabilidades.

7. **El MSE de entrenamiento baja al subir el grado y el de validación sube. ¿Qué indica?** Sobreajuste: más flexibilidad está aprendiendo detalles del entrenamiento y empeora la generalización.

8. **El p-valor F global es pequeño, pero algunos p-valores individuales no. ¿Contradicción?** No. El F evalúa conjuntamente los predictores; las pruebas individuales evalúan cada coeficiente, con incertidumbre y posible correlación entre predictores.

9. **Un coeficiente categórico es 4000 frente a una base de referencia. ¿Qué aclarar?** Indicar la categoría de referencia, que se mantienen los demás predictores constantes, la unidad de la respuesta y que se trata de una asociación ajustada.

10. **Una exactitud de 96 % se calculó sobre los datos de entrenamiento. ¿Es la precisión esperada en nuevos casos?** No necesariamente. Es tasa aparente y puede estar sesgada hacia arriba; hace falta evaluar en datos no usados para ajustar, idealmente con validación adecuada.

11. **Se aplicó SMOTE a toda la base y luego se hizo validación cruzada. ¿La tasa es una evaluación independiente?** No. Los sintéticos pudieron usar observaciones que luego quedaron en pliegues de validación; hay fuga de información. El remuestreo debe hacerse dentro de cada pliegue de entrenamiento y la evaluación final sobre datos originales no remuestreados.

11. Resumen de consulta rápida

Salida	**Lectura principal**
Coeficiente lineal $\widehat{\beta}_j$	Cambio medio estimado en Y por unidad de X_j, manteniendo constantes los demás predictores.
Valor p individual	Evidencia contra $H_0 : \beta_j = 0$; no mide tamaño ni importancia práctica.
Prueba F / p global	Evidencia de que el conjunto de pendientes aporta frente al modelo sin predictores.
R^2	Variación explicada en entrenamiento con intercepto; en test puede ser negativo. No es accuracy ni causalidad.
MSE / RMSE / MAE	Errores de predicción; menor suele ser mejor solo en comparaciones equivalentes.
Residuos vs predichos	Curva sugiere no linealidad; abanico sugiere heteroscedasticidad; patrones sugieren estructura restante.
Odds ratio e^{β_j}	Multiplicador de las odds por unidad del predictor; comparar con 1.
Pseudo-R^2 logístico	Resumen relativo basado en verosimilitud; no es porcentaje de varianza explicada.
LLR p-value	Prueba global de mejora del modelo logístico frente al modelo nulo.
Matriz de confusión	Aciertos y errores por clase; confirmar orientación de ejes y clase positiva.
Sensibilidad / especificidad	Detección de positivos reales / reconocimiento de negativos reales.
Precisión / NPV	Probabilidad de acierto condicionada a predicción positiva / negativa.
ROC / AUC	Discriminación al variar umbral; requiere probabilidades o puntuaciones, no solo etiquetas; AUC no elige el umbral operativo.
F1 / support / promedios	F1 resume precisión y recall; support cuenta casos y macro/weighted promedian las métricas de clase de forma distinta.
SMOTE / sobremuestreo	Balancea datos de entrenamiento con sintéticos; aplicarlo antes de la validación produce fuga y métricas no representativas.