

Guía integral para el primer parcial

Machine Learning

Conceptos, relaciones e interpretación de resultados

19 de septiembre de 2026

Alcance de la guía

Integra estadística descriptiva, fundamentos multivariados, análisis de componentes principales (ACP/PCA) y análisis de conglomerados. Está orientada a un examen en papel: prioriza reconocer salidas, explicar qué representan y formular conclusiones justificadas. La sintaxis de programación se omite, pero se conservan los resultados relevantes de los cuadernos.

Fuentes integradas: repaso descriptivo, diapositivas de álgebra y análisis multivariado, cuadernos 1 y 3, Unidad 3 con Online Retail y Encuentro 4 de clustering.

Convención numérica: los valores copiados de salidas de Python conservan el punto decimal (0.514); en notación española equivalen a 0,514.

1. Cómo usar esta guía y cómo responder el parcial

En casi toda salida estadística conviene responder en cuatro pasos:

1. **Identificar el objeto:** tabla descriptiva, matriz de correlaciones, valores propios, cargas, dendrograma, centroides, silueta, etc.
2. **Leer la magnitud y el signo:** qué valor es mayor, menor, cercano a cero, positivo o negativo.
3. **Traducirlo al problema:** nombrar las variables y observaciones concretas; no limitarse a repetir números.
4. **Agregar una cautela:** correlación no implica causalidad; los rótulos de clusters son arbitrarios; un plano PCA puede perder información; un atípico no es automáticamente un error.

Clave para el parcial

Una buena respuesta tiene la forma: “La salida muestra *qué se midió*; el valor o patrón relevante es *cuál*; por lo tanto, en el contexto del problema *significa esto*; la conclusión debe tomarse con *esta limitación*”. Evitar respuestas puramente mecánicas como “CP1 explica 30,3 %” sin decir qué implica.

1.1. Prioridad real de estudio según el formato del parcial

La información disponible sobre parciales anteriores indica que la evaluación se concentra en **interpretar salidas dentro de un caso**. La teoría sigue siendo necesaria para justificar la lectura, pero no todas las partes de la guía deben estudiarse con la misma profundidad.

Prioridad	Qué estudiar	Qué debería poder hacer
Muy alta	Sección “Salidas de Colab”, gráficos y tablas reales	Reconocer la salida, localizar el patrón relevante, traducirlo al caso y escribir una conclusión con cautela.
Alta	Correlación, PCA y clustering	Interpretar signo y magnitud; varianza explicada; matriz de pesos; dendrograma; silueta; centroides y comparación de métodos.
Media	Descriptiva, estandarización, faltantes y atípicos	Explicar cómo el preprocesamiento modifica las salidas y detectar problemas en <code>info()</code> o <code>describe()</code> .
Apoyo	Álgebra matricial y derivaciones	Comprender qué representan los objetos y las fórmulas. No priorizar demostraciones ni cálculos manuales largos.

Forma recomendada de estudiar

Primero intentar explicar cada salida sin mirar el texto. Después usar la teoría para corregir o completar la respuesta. Memorizar una definición aislada tiene menor prioridad que poder aplicar correctamente el concepto a variables concretas. La excepción más probable es la definición matemática del coeficiente de correlación, que debe conocerse junto con su interpretación.

1.2. Mapa conceptual del programa

Bloque	Pregunta central
Descripción de datos	¿Qué tipo de variables hay, cómo se distribuyen, qué asociaciones existen y qué problemas de calidad aparecen?
Preparación	¿Las escalas son comparables? ¿Hay faltantes o atípicos que puedan alterar los resultados?
PCA/ACP	¿Puede resumirse un conjunto de variables correlacionadas mediante pocas dimensiones sin perder demasiada información?
Conglomerados	¿Pueden agruparse las observaciones de modo que sean parecidas dentro de cada grupo y diferentes entre grupos?
Validación e interpretación	¿Cuántas dimensiones o grupos conservar? ¿La solución es clara, estable y útil?

2. Aprendizaje automático y análisis multivariado

Definición

El **aprendizaje automático** consiste en aprender patrones a partir de ejemplos. En lugar de escribir una regla para cada situación, se entregan datos y el método busca regularidades que permitan describir casos, formar grupos o hacer predicciones.

Aprendizaje supervisado: existe una variable respuesta o etiqueta conocida durante el entrenamiento. Se busca aprender la relación entre predictores y respuesta. Si la respuesta es cuantitativa se habla típicamente de regresión; si es categórica, de clasificación.

Aprendizaje no supervisado: no existe una etiqueta objetivo. Se intenta descubrir estructura interna. PCA reduce dimensiones y clustering forma grupos. Los temas centrales de esta bibliografía pertenecen principalmente a esta rama.

En esta guía, **ACP** y **PCA** designan la misma técnica (análisis de componentes principales y *principal component analysis*); **cluster**, **conglomerado** y **grupo** se usan como equivalentes. Se reserva **clasificación supervisada** para predecir etiquetas conocidas y **clustering** para descubrir grupos sin etiqueta previa.

	Supervisado	No supervisado
Información inicial	Predictores y respuesta conocida	Solo variables descriptivas
Objetivo	Predecir o clasificar casos nuevos	Resumir, visualizar o descubrir grupos
Evaluación	Comparación con valores verdaderos	Criterios internos, estabilidad e interpretación
Ejemplos	Regresión, árbol de clasificación	PCA, cluster jerárquico, K-means

2.1. La matriz de datos

Una base con n observaciones y p variables puede representarse por una matriz X de dimensión $n \times p$:

$$X = \begin{pmatrix} x_{11} & \cdots & x_{1p} \\ \vdots & \ddots & \vdots \\ x_{n1} & \cdots & x_{np} \end{pmatrix}.$$

Cada **fila** es una observación o individuo, cada **columna** una variable y cada celda un dato. El mismo conjunto puede mirarse en el espacio de observaciones $\mathbb{R}^p$ (cada individuo es un punto caracterizado por p variables) o en el espacio de variables $\mathbb{R}^n$ (cada variable es un vector con n valores).

Clave para el parcial

Antes de interpretar una salida, identificar siempre la unidad de análisis. En Online Retail, la tabla original tiene transacciones como filas; después de agrupar se obtiene una tabla con clientes como filas y las variables RFM como columnas. Cambió la unidad de análisis.

3. Repaso de estadística descriptiva

3.1. Población, muestra y ramas de la estadística

La **población** es el conjunto de interés; una **muestra** es un subconjunto observado. Una medida poblacional es un **parámetro**; su equivalente calculado en una muestra es un **estadístico**. La estadística descriptiva organiza y resume los datos observados. La estadística inferencial utiliza una muestra para extraer conclusiones sobre la población, con incertidumbre cuantificable.

3.2. Tipos de variables y escalas

Tipo	Característica	Ejemplos y herramientas adecuadas
Categorica nominal	Categorías sin orden intrínseco	Sexo, país, especie. Frecuencias, porcentajes, moda, barras o sectores.
Categorica ordinal	Categorías ordenables, sin distancias numéricas aseguradas	Poco/moderadamente/muy satisfecho. Frecuencias, mediana, cuantiles y barras ordenadas.
Cuantitativa discreta	Conteos, usualmente valores enteros	Número de compras. Media, mediana, dispersión, barras o bastones.
Cuantitativa continua	Puede asumir cualquier valor de un intervalo	Ingreso, gasto, altura. Media, cuantiles, varianza, histograma y boxplot.

En una escala **nominal** solo importan igualdad y diferencia. En una escala **ordinal** también existe orden. En una escala de **intervalo**, las diferencias son interpretables pero el cero puede ser arbitrario. En una escala de **razón**, además existe cero absoluto y son interpretables los cocientes.

3.3. Frecuencias y gráficos

En una tabla agrupada: LI y LS son límites de clase; MC es la marca de clase; FA la frecuencia absoluta; FR la frecuencia relativa; FAA y FRA son frecuencias acumuladas. La frecuencia relativa expresa una proporción y la acumulada responde “¿qué proporción no supera este límite?”.

Si f_i es la cantidad de casos de la clase i y n el total,

$$h_i = \frac{f_i}{n}, \quad F_i = \sum_{j \leq i} f_j, \quad H_i = \sum_{j \leq i} h_j.$$

h_i es la frecuencia relativa, F_i la absoluta acumulada y H_i la relativa acumulada. La suma de todas las frecuencias absolutas es n y la de las relativas es 1. Las acumuladas solo tienen sentido cuando las categorías o intervalos pueden ordenarse.

- **Barras:** categorías o valores discretos. La altura representa frecuencia; las barras se separan.
- **Histograma:** variable continua agrupada en intervalos. Las barras son contiguas y la forma permite estudiar simetría, colas y posibles modas.
- **Pareto:** barras ordenadas de mayor a menor, útil para priorizar categorías.
- **Ojiva:** frecuencia acumulada; permite localizar percentiles.
- **Dispersión:** dos variables cuantitativas; muestra dirección, fuerza, forma, grupos y atípicos de la asociación.
- **Boxplot:** resume mediana, cuartiles, rango intercuartílico, brazos y observaciones potencialmente atípicas.

3.4. Medidas de posición

La **media** usa todos los valores, posee la misma unidad que la variable y es sensible a extremos. La **mediana** deja 50 % de los datos a cada lado y es resistente a extremos. La **moda** es el valor o categoría más frecuente y puede no ser única.

Para datos no agrupados, la media muestral es

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

Su propiedad de equilibrio es $\sum_i (x_i - \bar{x}) = 0$. Además, es el valor que minimiza la suma de desvíos cuadrados $\sum_i (x_i - c)^2$. La mediana, en cambio, minimiza la suma de desvíos absolutos $\sum_i |x_i - c|$. Esta diferencia explica por qué la media reacciona con más fuerza a los extremos.

Los **cuartiles** dividen los datos ordenados en cuatro partes: Q_1 deja aproximadamente 25 % por debajo, Q_2 es la mediana y Q_3 deja aproximadamente 75 % por debajo. Deciles y percentiles dividen en diez y cien partes.

Cómo interpretarlo

Si media y mediana son parecidas, la distribución puede ser aproximadamente simétrica, aunque esto no lo prueba. En distribuciones unimodales con asimetría derecha suele cumplirse $\text{moda} < \text{mediana} < \text{media}$, porque la cola de valores altos arrastra la media. Con asimetría izquierda suele ocurrir $\text{media} < \text{mediana} < \text{moda}$. Estas relaciones son orientativas y pueden fallar en distribuciones multimodales o irregulares.

3.5. Dispersión y forma

La **varianza** promedia desvíos cuadrados respecto de la media; queda expresada en unidades al cuadrado. El **desvío estándar** es su raíz y vuelve a la unidad original. Valores altos indican mayor separación respecto de la media; cero indica que todos los valores son iguales.

En una muestra,

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2, \quad s = \sqrt{s^2}.$$

El divisor $n-1$ aparece cuando la varianza muestral se usa para estimar la varianza poblacional. El desvío no indica si los valores están por encima o debajo de la media: solo resume la magnitud típica de separación.

El **rango** es máximo menos mínimo y depende fuertemente de extremos. El **rango intercuartílico**, $RI = Q_3 - Q_1$, describe la amplitud del 50% central y es resistente. El **coeficiente de variación**, $CV = s/\bar{x}$ (frecuentemente expresado en porcentaje), mide dispersión relativa y permite comparar variables en escalas distintas cuando la media es significativa y no está cerca de cero.

Una alternativa robusta es la **desviación absoluta mediana**:

$$MAD = \text{Mediana}\{|x_i - \text{Mediana}(x)|\}.$$

Como se centra en la mediana y vuelve a tomar una mediana, cambia poco ante unos pocos extremos. La pareja media–desvío estándar es adecuada para distribuciones aproximadamente simétricas sin extremos severos; la pareja mediana–RI o mediana–MAD es más resistente.

La **asimetría** describe la falta de simetría: positiva equivale a cola derecha; negativa, a cola izquierda; cercana a cero, a simetría aproximada. La **curtosis** describe el peso de las colas y concentración respecto de una referencia normal: una curtosis elevada suele asociarse con colas más pesadas y mayor presencia potencial de extremos. No debe confundirse curtosis con “altura del pico” únicamente.

Hay dos convenciones de salida. La **curtosis de Pearson** vale 3 para una normal; el **exceso de curtosis** resta 3 y vale 0. Los valores del ejemplo de empleados son compatibles con exceso de curtosis. Por eso, antes de afirmar “mayor o menor que la normal”, debe identificarse qué convención usa la tabla.

Clave para el parcial

Para comparar homogeneidad de dos variables con unidades o medias muy diferentes es preferible el CV, no los desvíos estándar en bruto. Un CV alto implica mayor variabilidad relativa. Si la media es cero o muy cercana a cero, el CV pierde sentido.


3.6. Boxplot y datos atípicos univariados

Los límites teóricos habituales son

$$LI = Q_1 - 1.5RI, \quad LS = Q_3 + 1.5RI.$$

Los brazos llegan hasta el mínimo y máximo observados que permanecen dentro de esos límites; los puntos exteriores se marcan como **atípicos potenciales**. Un boxplot también informa posición de la mediana, dispersión central y asimetría.

Gráfico de caja y brazos (box plot)



Fuente: Unidad 1: Repaso descriptiva, anatomía del gráfico de caja y brazos.

La caja contiene el 50 % central de los datos: comienza en Q_1 y termina en Q_3 . La línea interior es la mediana. Los límites $Q_1 - 1.5RI$ y $Q_3 + 1.5RI$ son cercas teóricas, no necesariamente los extremos de los brazos: cada brazo llega hasta el dato observado más lejano que todavía permanece dentro de la cerca. Los puntos que la superan se dibujan por separado.

Otra regla exploratoria usa puntuaciones estandarizadas:

$$z_i = \frac{x_i - \bar{x}}{s}, \quad |z_i| \geq 3$$

como señal de observación extrema. Este criterio depende de media y desvío, que a su vez son sensibles a atípicos, y resulta más defendible bajo una forma aproximadamente normal. El criterio del boxplot es más robusto y no exige normalidad.

Los cuadernos también exploran filtros mediante cuantiles 2.5 % y 95 %, o límites más amplios basados en varias veces el RI. Son **decisiones empíricas de filtrado**, no la regla teórica estándar del boxplot. Un intervalo 2.5–95 % elimina por construcción una fracción apreciable de casos y, además, es asimétrico en sus colas; debe informarse y justificarse porque puede cambiar fuertemente PCA y clustering.

Atención

“Atípico” no significa necesariamente “dato incorrecto”. Puede ser error de carga, caso legítimo poco frecuente o subpoblación relevante. Antes de eliminarlo hay que investigar su origen y medir su influencia. El criterio univariado puede no detectar un caso atípico por combinación de variables.

3.7. Lectura de un reporte exploratorio automático

Los cuadernos generan reportes de análisis exploratorio con resúmenes por variable y alertas. Aunque el examen no evalúe el programa que los produce, puede presentar fragmentos de esas salidas. Conviene reconocer:

- **número de observaciones y variables**: dimensión de la base;
- **tipo de dato**: numérico, categórico, fecha o texto; un tipo incorrecto puede impedir un análisis apropiado;
- **missing count / missing %**: cantidad y proporción de faltantes;

- **distinct / unique:** cantidad de valores diferentes; 100 % de valores únicos puede indicar un identificador, no una variable explicativa;
- **zeros y negatives:** no son necesariamente errores, pero deben ser compatibles con la definición de la variable;
- **minimum, maximum, quantiles:** permiten detectar rangos imposibles, asimetría y extremos;
- **skewness y kurtosis:** resumen forma y colas;
- **high correlation:** posible información redundante, inestabilidad o doble ponderación;
- **duplicates:** filas repetidas que podrían representar duplicación accidental o transacciones legítimamente iguales.

Una alerta no constituye una decisión. Por ejemplo, una variable marcada como “unique” puede ser un código de cliente necesario para agrupar transacciones, aunque no deba incluirse como variable numérica en PCA o K-means. Una correlación alta puede justificar PCA, pero no obliga a eliminar una de las variables si ambas tienen interpretación sustantiva.

3.8. Lectura integrada del ejemplo de empleados

La salida descriptiva de 100 empleados resume educación (EDUCAC), ingreso personal (INGRPER) y antigüedad en la empresa (ANTEMP):

Medida	EDUCAC	INGRPER	ANTEMP
Media	14.29	32.45	7.91
Desvío estándar	2.79	15.61	8.08
CV (%)	19.50	48.11	102.16
Mediana	14.00	30.30	5.00
Asimetría	0.23	0.90	1.79
Curtosis	-0.34	0.56	3.21

EDUCAC es relativamente homogénea y casi simétrica. INGRPER presenta mayor variabilidad relativa y asimetría derecha. ANTEMP tiene el mayor CV, media claramente superior a la mediana, fuerte asimetría positiva y curtosis alta: predominan antigüedades bajas con una cola de empleados muy antiguos. Comparar solo los desvíos sería incorrecto porque las variables tienen unidades distintas.

Al separar INGRPER por sexo, la muestra informa media 25.45 y mediana 23.90 para mujeres, frente a media 37.12 y mediana 35.90 para varones. Es una diferencia descriptiva en los datos observados: sin un procedimiento inferencial y sin controlar otras variables no puede afirmarse que represente toda la población ni atribuirse causalmente al sexo.

4. Descripción multivariada y asociación

4.1. Centrado, estandarización y normalización

Centrar una variable significa restarle su media: los nuevos valores tienen media cero, pero conservan el desvío original. **Estandarizar** mediante puntuaciones z significa restar la media y dividir por el desvío estándar:

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}.$$

La variable estandarizada tiene media aproximada cero y varianza uno. Un $z = 2$ indica que el caso está dos desvíos estándar por encima de la media; $z = -1.5$, uno y medio por debajo.

La transformación min-max lleva típicamente los valores al intervalo $[0, 1]$:

$$z_{ij} = \frac{x_{ij} - \min(x_j)}{\max(x_j) - \min(x_j)}.$$

No es lo mismo que estandarizar. Ambas cambian la escala, pero la puntuación z expresa distancia respecto de la media y min-max expresa posición dentro del rango.

Clave para el parcial

Estandarizar es especialmente importante en PCA, distancias y clustering cuando las variables tienen unidades o variabilidades diferentes. Sin estandarización, una variable medida en miles puede dominar aunque no sea conceptualmente más importante.

4.2. Covarianza y correlación

La **covarianza** indica si dos variables tienden a moverse juntas. Es positiva cuando valores altos de una suelen acompañarse de valores altos de la otra; negativa cuando una tiende a subir mientras la otra baja; y cercana a cero cuando no se observa un movimiento lineal conjunto claro. Como depende de las unidades, su tamaño no sirve para comparar directamente pares distintos.

La **correlación de Pearson** expresa la misma idea en una escala común de -1 a 1 . Puede pensarse como una medida de qué tan bien los puntos siguen una recta:


- cercana a 1: asociación lineal positiva fuerte;
- cercana a -1 : asociación lineal negativa fuerte;
- cercana a 0: asociación lineal débil o ausente.

El signo indica dirección y $|r|$ indica intensidad. $r = 0$ no garantiza independencia ni ausencia de relación no lineal. La correlación tampoco demuestra causalidad y puede ser afectada por atípicos.

Los calificativos “débil”, “moderada” o “fuerte” dependen del campo y no poseen cortes universales. Además, una correlación alta puede surgir por mezcla de grupos o por tendencia temporal. Siempre debe examinarse el diagrama de dispersión: una misma correlación puede corresponder a nubes con formas muy diferentes.

Medidas de dispersión multivariada

peso	estatura
56	170
55	157
65	150
68	171
72	175
53	163
55	165
61	163
65	165
48	155
62	170
72	180
46	162
84	182
85	176
70	180



	Peso	Estatura
Desvio estandar	11,06 kg	9,12cm
Covarianza	72,08	
Coef de correlación	0,714	

Fuente: Unidad 1: Repaso descriptiva, ejemplo Peso-Estatura.

En el ejemplo, la nube tiene una tendencia ascendente: pesos mayores suelen acompañarse de estaturas mayores. El coeficiente $r = 0.714$ resume una asociación lineal positiva apreciable. Los desvíos estándar describen cada variable por separado y la covarianza 72.08 describe su movimiento conjunto, pero conserva unidades; la correlación permite valorar la intensidad en una escala común. Antes de informar r , también se revisan atípicos, curvaturas y posibles grupos en la nube.

La **matriz de covarianzas** es un mapa conjunto de la variabilidad: la diagonal dice cuánto varía cada variable y las demás celdas indican qué pares se mueven juntos. La **matriz de correlaciones** presenta esas asociaciones en la escala común de -1 a 1 ; por eso tiene unos en la diagonal. Ambas son simétricas: leer fila j , columna k equivale a leer fila k , columna j .

La **traza** es simplemente la suma de la diagonal. En una matriz de covarianzas suma todas las varianzas. Si se trabaja con p variables estandarizadas, cada una aporta varianza 1 y la traza de la matriz de correlaciones vale p .

Para dos variables, las expresiones muestrales son


$$s_{jk} = \frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{x}_j)(x_{ik} - \bar{x}_k), \quad r_{jk} = \frac{s_{jk}}{s_j s_k}.$$

La matriz $S = (s_{jk})$ reúne las covarianzas. Si D es la matriz diagonal de desvíos estándar, la matriz de correlaciones se obtiene conceptualmente como

$$R = D^{-1} S D^{-1}.$$

Por eso correlacionar equivale a medir covarianzas luego de estandarizar.

Matriz de correlación



The image shows handwritten notes and diagrams illustrating the calculation of the correlation matrix R from the covariance matrix S and the standard deviation matrix D .

At the top, the formula $R = D^{-1} S D^{-1}$ is written. Below it, a matrix S is shown with elements $s_{11}, s_{12}, s_{21}, s_{22}$. To the right, a matrix R is shown with elements $\frac{s_{11}}{\sqrt{s_{11}} \sqrt{s_{11}}}, \frac{s_{12}}{\sqrt{s_{11}} \sqrt{s_{22}}}, \frac{s_{21}}{\sqrt{s_{21}} \sqrt{s_{22}}}, \frac{s_{22}}{\sqrt{s_{22}} \sqrt{s_{22}}}$.

Below the formula, a matrix D is shown as $D = \text{diag}(s_{11}, s_{22}, \dots, s_{pp})$. To the left, a matrix D is shown with elements $1, 0, 0, 0, 1$. Below this, a matrix D is shown with elements $1, 0, 0, 0, 1$ and a note "las variables no correlacionan".

At the bottom, the calculation of R is shown as a product of three matrices:

$$R = \begin{bmatrix} 1 & 0 \\ 0 & \frac{1}{\sqrt{1,33}} \end{bmatrix} \times \begin{bmatrix} 1 & 0 \\ 0 & 1,33 \end{bmatrix} \times \begin{bmatrix} 1 & 0 \\ 0 & \frac{1}{\sqrt{1,33}} \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

Fuente: Machine learning, diapositiva "Matriz de correlación".

La captura permite reconocer la estructura típica de la salida: los unos de la diagonal comparan cada variable consigo misma; las posiciones simétricas representan el mismo par en orden inverso; y cada elemento fuera de la diagonal es una asociación entre dos variables. La expresión $R = D^{-1} S D^{-1}$ muestra visualmente que la matriz de correlaciones se obtiene reescalando las covarianzas por los desvíos estándar.

La matriz de datos centrados es $X_c = X - \mathbf{1}\bar{\mathbf{x}}'$. A partir de ella,

$$S = \frac{1}{n-1} X_c' X_c.$$

$X_c'X_c$ es la matriz de **sumas de cuadrados y productos cruzados**: en la diagonal contiene sumas de cuadrados de cada variable y fuera de ella productos cruzados entre pares. Es el puente entre la geometría de los vectores y las medidas de asociación.

Dos resúmenes globales de dispersión son:

$$\text{varianza total} = \text{traza}(S) = \sum_{j=1}^p s_{jj}, \quad \text{varianza generalizada} = |S|.$$

La traza suma variabilidad marginal y depende de la escala. El determinante considera conjuntamente volumen y correlaciones: vale cero si la nube queda contenida en un subespacio de dimensión menor, por ejemplo ante una combinación lineal exacta. No deben compararse determinantes calculados con distinto número de variables o escalas sin ajuste.

Ejemplo de salida

En el cuaderno de PCA, $r(\text{Cashvent}, \text{Benvent}) = 0.958$: asociación positiva lineal muy fuerte y posible redundancia. En cambio, $r(\text{Ventact}, \text{Inmoactt}) = -0.449$: asociación negativa moderada. Estos patrones justifican intentar resumir información con componentes.

4.3. Distancias

Una **distancia** traduce la idea de “qué tan distintos son dos casos” a un número: cero significa que coinciden en las variables consideradas y un valor mayor significa mayor separación. La definición matemática exige que sea no negativa, simétrica y coherente con el recorrido entre puntos.

Para observaciones r y s con p variables,

$$d_E(r, s) = \sqrt{\sum_{j=1}^p (x_{rj} - x_{sj})^2}, \quad d_{\text{Man}}(r, s) = \sum_{j=1}^p |x_{rj} - x_{sj}|.$$

La distancia de Minkowski generaliza ambas:

$$d_q(r, s) = \left(\sum_{j=1}^p |x_{rj} - x_{sj}|^q \right)^{1/q}.$$

- **Euclídea**: la distancia “en línea recta” entre dos puntos. Es la más intuitiva, pero una variable medida con números grandes puede dominarla.
- **Euclídea al cuadrado**: evita la raíz y acentúa diferencias grandes; aparece en Ward y K-means.
- **Manhattan**: imagina desplazarse por calles en cuadrícula: se suman por separado los cambios de cada variable. Corresponde a Minkowski con parámetro 1.
- **Minkowski**: familia que contiene Manhattan y euclídea.
- **Euclídea estandarizada**: calcula la distancia luego de corregir escalas o variabilidades.
- **Mahalanobis**: mide si un caso es extraño respecto de la forma habitual de la nube. Una diferencia en una dirección donde los datos varían mucho pesa menos; una diferencia en una dirección poco habitual pesa más.
- **Gower**: permite comparar casos cuando la base mezcla números y categorías. Convierte cada variable a una contribución comparable y luego las combina.

Matriz de distancias euclídeas al cuadrado

	E1	E2	E3	E4	E5	E6	E7	E8
E1	0							
E2	32	0						
E3	180	68	0					
E4	241	121	13	0				
E5	841	1105	1369	1314	0			
E6	1181	1445	1649	1544	50	0		
E7	1066	1210	1234	1089	225	125	0	
E8	1445	1613	1625	1448	314	144	29	0

Fuente: Machine learning, ejemplo de ocho empresas.

En una **matriz de distancias**, la diagonal vale cero porque cada caso está a distancia cero de sí mismo. La matriz es simétrica, aunque la salida puede mostrar solo uno de sus triángulos. Para encontrar los casos inicialmente más próximos se busca el menor valor fuera de la diagonal: en el ejemplo es 13 para E3–E4; luego aparecen E7–E8 con 29 y E1–E2 con 32. Esta lectura anticipa las primeras fusiones de un algoritmo jerárquico.

Dos personas pueden tener gran diferencia euclídea por una variable muy dispersa. Mahalanobis reduce el peso de direcciones naturalmente variables y reconoce redundancia entre variables correlacionadas. Por eso es útil para atípicos multivariados.

Su forma cuadrática es

$$d_{\text{Mah}}^2(\mathbf{x}, \boldsymbol{\mu}) = (\mathbf{x} - \boldsymbol{\mu})' S^{-1} (\mathbf{x} - \boldsymbol{\mu}).$$

Si S fuera la identidad, se reduce a la distancia euclídea al cuadrado. Si dos variables están muy correlacionadas, Mahalanobis evita contar dos veces casi la misma dirección. Requiere que S sea invertible; una colinealidad exacta o demasiadas variables respecto de los casos puede impedirlo.

4.4. Normalidad y atípicos multivariados

La **normal multivariada** es la versión de la campana normal cuando se observan varias variables a la vez. En lugar de una campana sobre una recta, forma una nube elíptica alrededor del centro. El vector de medias ubica ese centro y la matriz de covarianzas determina qué tan extendida e inclinada queda la nube.

Su densidad tiene la forma


$$f(\mathbf{x}) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp \left[-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})' \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right].$$

El exponente depende de la distancia de Mahalanobis: puntos con igual distancia tienen igual densidad. Con correlación positiva, la elipse se inclina en sentido ascendente; con correlación negativa, descendente; con correlación cero y varianzas iguales, las curvas son circulares.

Distribución Normal Bivariada

Vector de medias nulo, varianzas unitarias y correlación 0.70

$$f(x, y) = \frac{1}{4.48} \exp(-0.98x^2) \exp(1.37xy) \exp(-0.98y^2)$$




Fuente: Machine learning, normales bivariadas con correlaciones 0.70 y -0.70.

Distribución Normal Bivariada

Vector de medias nulo, varianzas unitarias y correlación -0.70

$$f(x, y) = \frac{1}{4.48} \exp(-0.98x^2) \exp(-1.37xy) \exp(-0.98y^2)$$



Las curvas de nivel permiten ver la correlación sin calcularla. A la izquierda, la elipse asciende de izquierda a derecha: ambas variables tienden a aumentar juntas. A la derecha descende: valores altos de una tienden a acompañarse de valores bajos de la otra. La correlación modifica orientación y forma de la nube, no solamente la altura de la superficie.

La normalidad multivariada implica normalidad de cada variable y de toda combinación lineal. Sin embargo, que todas las variables sean marginalmente normales no garantiza por sí solo normalidad conjunta. Por eso una colección de pruebas univariadas no reemplaza el diagnóstico multivariado.

Para diagnosticar normalidad univariada pueden aparecer distintas pruebas. Las principales del material son Shapiro-Wilk y Kolmogorov-Smirnov con corrección de Lilliefors. En ambos casos usuales:

$$H_0 : \text{la distribución es normal}, \quad H_1 : \text{no es normal}.$$

Si $p\text{-valor} < \alpha$ (por ejemplo, 0.05), se rechaza normalidad; si es mayor, no hay evidencia suficiente para rechazarla. *No rechazar* no equivale a demostrar que la distribución es exactamente normal. Con muestras grandes, pequeñas desviaciones pueden resultar significativas; conviene acompañar con gráficos.

Kolmogorov-Smirnov compara la función de distribución empírica $F_n(x)$ con una distribución teórica $F_0(x)$ mediante la máxima diferencia vertical:

$$D = \sup_x |F_n(x) - F_0(x)|.$$

La corrección de Lilliefors se usa cuando los parámetros de la normal se estiman con la propia muestra. Shapiro-Wilk mide, en esencia, el grado de alineación entre los datos ordenados y lo esperado bajo normalidad. En ambos, un estadístico “más extremo” conduce a un p -valor pequeño; la regla de decisión se basa en el p -valor, no en comparar directamente estadísticas de pruebas distintas.

En la bibliografía, EDUCAC presenta $p = 0.0014$ e INGRPER y ANTEMP $p < 0.0001$: al nivel 5 % se rechaza normalidad para las tres variables.

Para normalidad multivariada se ordenan distancias de Mahalanobis al cuadrado y se comparan con cuantiles de una χ_p^2 . Una alineación aproximadamente recta apoya el supuesto; desviaciones sistemáticas o puntos extremos lo cuestionan. Para detectar atípicos, un caso cuya distancia cuadrada supera el cuantil crítico de χ_p^2 se marca como potencial atípico multivariado.

En el gráfico QQ multivariado, un eje contiene las distancias $d_{(i)}^2$ ordenadas y el otro los cuantiles teóricos $\chi_{p,(i-0.5)/n}^2$. La lectura se centra en la forma:

- puntos aproximadamente alineados: compatibilidad razonable con normalidad multivariada;
- curvatura general: discrepancia sistemática de forma o colas;
- pocos puntos muy separados en el extremo superior: posibles atípicos;
- varios extremos por encima de la línea: colas más pesadas que las normales.

No se interpreta la pendiente como correlación entre variables. Tampoco basta una nube “más o menos recta” si las últimas observaciones se apartan fuertemente, porque justamente allí suelen aparecer los casos influyentes.


Prueba gráfica de Normalidad Multivariada

Los valores de d^2 se ordenan de menor a mayor y se grafican pares

$$\left[d_{(s)}^2, \chi_p^2\left(\frac{s-0.5}{n}\right) \right]$$

Siendo la segunda componente el percentil de la distribución con grados de libertad

Si los datos provienen de una población normal multivariada el gráfico obtenido será aproximadamente lineal





Fuente: Machine learning, prueba gráfica de normalidad multivariada.

En la captura, la mayor parte de los puntos sigue aproximadamente la diagonal, aunque la atención debe concentrarse también en los extremos. La recta funciona como referencia: cercanía global apoya compatibilidad con la normal multivariada; separación sistemática, curvatura o puntos finales aislados aportan evidencia en contra. El gráfico es diagnóstico y debe combinarse con el contexto, el tamaño muestral y otros resultados.

Ejemplo de salida

Con tres variables y nivel 95 %, el cuaderno obtiene un corte cercano a 7.815. Una observación con distancia de Mahalanobis al cuadrado superior al corte se señala como atípica multivariada. Esto es una regla de detección, no una orden automática de borrado.



Fuente: Cuaderno 4 IIA 2025, biplot antes y después del filtrado exploratorio de atípicos.

El gráfico izquierdo está dominado por unos pocos casos muy alejados: la mayoría queda comprimida cerca del origen y su estructura casi no puede verse. Después del filtrado exploratorio usado en el

cuaderno, el gráfico derecho despliega mejor la nube central. La comparación demuestra que los atípicos pueden modificar escalas, componentes y visualización. No demuestra que deban eliminarse: primero debe decidirse si son errores, casos válidos o un segmento relevante y luego comparar formalmente ambas soluciones.

4.5. Datos faltantes

Las alternativas básicas son eliminar filas/variables o imputar valores. La decisión depende de cuánto falta, por qué falta y cuánto sesgo puede generar.

Conceptualmente se distinguen tres mecanismos:

- **MCAR**: los datos faltan por razones ajenas a las variables estudiadas, como una pérdida accidental de formularios. Eliminar casos reduce información, pero no favorece sistemáticamente un perfil.
- **MAR**: la ausencia se relaciona con información que sí conocemos. Por ejemplo, cierto grupo de edad responde menos una pregunta. Esa información observada puede ayudar a imputar o ajustar.
- **MNAR**: la ausencia se relaciona con el dato que falta. Por ejemplo, quienes tienen ingresos muy altos evitan declararlos. Es el caso más difícil porque el motivo depende justamente de información no observada.
- **Eliminación**: simple, pero reduce tamaño muestral y puede sesgar si los faltantes no son completamente aleatorios.
- **Imputación por media**: conserva cantidad de casos, pero reduce artificialmente la variabilidad y debilita relaciones; no incorpora incertidumbre.
- **Imputaciones más elaboradas**: usan otras variables o múltiples valores plausibles; suelen preservar mejor la estructura, pero requieren más supuestos.

Clave para el parcial

Si una salida pasa de 224 casos completos a 229 luego de imputar, la interpretación es que se recuperaron observaciones. No significa que se haya recuperado información real sin costo: los valores imputados son estimaciones y pueden alterar varianzas, correlaciones, PCA y clusters.

5. Álgebra lineal: lo necesario para interpretar

Alcance de esta sección

Este bloque sirve para comprender por qué aparecen matrices, valores propios, pesos y formas cuadráticas en las salidas. Para el formato esperado del parcial, la prioridad es reconocer qué representa cada objeto y cómo afecta la interpretación; no memorizar demostraciones ni reproducir operaciones matriciales extensas.

No se espera efectuar operaciones extensas, pero sí comprender el significado de los objetos que sostienen PCA y las distancias.

5.1. Vectores

Un vector es una lista ordenada de valores y puede verse como un punto o una dirección. Su **norma** es su longitud; la norma euclídea conecta directamente con la distancia. La suma combina desplazamientos; multiplicar por un escalar cambia longitud y, si el escalar es negativo, sentido.

El **producto interno** relaciona longitud y ángulo. Si el producto interno es cero, los vectores son ortogonales. La correlación puede interpretarse geométricamente como el coseno del ángulo entre vectores centrados: ángulo pequeño implica correlación positiva alta; cercano a 180° , negativa alta; cercano a 90° ,

correlación lineal nula.

Para vectores $\mathbf{x}$ y $\mathbf{y}$,

$$\|\mathbf{x}\| = \sqrt{\mathbf{x}'\mathbf{x}}, \quad \cos(\theta) = \frac{\mathbf{x}'\mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|}.$$

Dos vectores son **linealmente independientes** si ninguno puede escribirse como combinación lineal de los demás. La independencia lineal determina cuántas direcciones genuinamente distintas contiene la información y se relaciona con el rango de una matriz.

La **proyección** de un vector sobre una dirección es la parte del vector explicada por esa dirección. En PCA, el puntaje de una observación es su proyección sobre el eje de una componente.

5.2. Matrices y propiedades

Concepto	Significado interpretativo
Matriz cuadrada	Igual cantidad de filas y columnas. Las matrices de covarianzas y correlaciones son $p \times p$.
Diagonal	Fuera de la diagonal hay ceros. Una covarianza diagonal indica variables no correlacionadas.
Simétrica	Coincide con su traspuesta. Covarianzas, correlaciones y distancias son simétricas.
Identidad	Unos en diagonal y ceros fuera; representa la transformación que no cambia el vector.
Traspuesta	Intercambia filas y columnas.
Determinante	Indica, en parte, si la transformación conserva volumen. Si vale cero, alguna dirección se perdió y la matriz no tiene inversa.
Inversa	Es la operación que permite “deshacer” una transformación. Mahalanobis usa la inversa de la covarianza; puede no existir si hay redundancia exacta.
Rango	Cantidad de direcciones independientes que realmente contiene la matriz; puede ser menor que el número de variables si hay redundancia.
Traza	Suma de la diagonal. En una covarianza es suma de varianzas; en PCA es variabilidad total.
Ortogonal	Su inversa es su traspuesta; preserva longitudes y ángulos. La rotación de PCA es ortogonal.
Idempotente	Aplicarla dos veces equivale a aplicarla una vez; aparece en matrices de proyección.
Definida positiva	Produce una cantidad positiva en cualquier dirección no nula. En covarianzas significa que existe variación positiva en todas las direcciones.

5.3. Valores y vectores propios

Un **vector propio** es una dirección especial que una matriz no gira: al aplicar la transformación, el vector continúa apuntando sobre la misma línea y solo cambia su longitud o sentido. El **valor propio** indica cuánto se estira o contrae esa dirección. Formalmente, $Au = \lambda u$.

Para matrices simétricas, los valores propios son reales y los vectores propios asociados a valores diferentes son ortogonales. En una matriz de covarianzas, los valores propios no pueden ser negativos porque representan cantidades de variación.

Los valores propios satisfacen la ecuación característica

$$\det(A - \lambda I) = 0.$$

No se espera resolverla a mano. Su función es encontrar esas direcciones especiales. Una matriz simétrica puede reconstruirse separando direcciones y magnitudes mediante la descomposición espectral

$$A = U\Lambda U',$$

donde las columnas de U son vectores propios ortonormales y Λ contiene los valores propios. En PCA, esta descomposición separa direcciones (U) y cantidades de variabilidad (Λ).

En PCA, los **vectores propios** definen las direcciones de las componentes y sus coeficientes se leen como pesos o cargas; los **valores propios** son las varianzas capturadas por cada componente. Se ordenan de mayor a menor.

5.4. Transformaciones lineales y formas cuadráticas

Una **transformación lineal** combina variables manteniendo proporciones y sumas. Geométricamente, una matriz puede rotar, proyectar, reflejar o cambiar la escala de una nube de puntos sin doblarla. Formalmente cumple $T(\mathbf{u} + \mathbf{v}) = T(\mathbf{u}) + T(\mathbf{v})$ y $T(c\mathbf{u}) = cT(\mathbf{u})$. PCA utiliza una rotación y, si se conservan pocos ejes, una proyección.

Una **forma cuadrática** combina todas las coordenadas de un caso y devuelve un solo número, normalmente interpretable como tamaño, distancia o variabilidad. Se escribe $\mathbf{x}'A\mathbf{x}$. Si nunca produce valores negativos, la matriz es semidefinida positiva; si además solo vale cero para el vector nulo, es definida positiva. Las matrices de covarianzas poseen esta propiedad porque una varianza nunca puede ser negativa.

La proyección ortogonal de $\mathbf{x}$ sobre un vector unitario $\mathbf{u}$ tiene coordenada $\mathbf{x}'\mathbf{u}$. Su varianza es

$$\text{Var}(X\mathbf{u}) = \mathbf{u}'S\mathbf{u}.$$

Esta forma cuadrática es precisamente la cantidad que PCA maximiza bajo la restricción $\mathbf{u}'\mathbf{u} = 1$.

6. Análisis de Componentes Principales (ACP/PCA)

6.1. Idea central, objetivo y conceptos básicos

Definición

El **ACP** reemplaza un conjunto de variables posiblemente relacionadas por una cantidad menor de nuevas variables resumen, llamadas **componentes principales**. No necesariamente resume todo en una única componente: pueden conservarse dos, tres o las que sean necesarias para no perder demasiada información. Cada componente combina las variables originales y las componentes quedan ordenadas desde la que conserva más variabilidad hasta la que conserva menos.

Por ejemplo, Gasto, Frecuencia y Cantidad de productos podrían moverse juntas. PCA podría resumir gran parte de ese patrón mediante una componente interpretable como “intensidad de consumo”. Si queda otro patrón relevante —por ejemplo, un contraste entre compra reciente y compra frecuente— aparecería en una segunda componente.

Concepto	Interpretación sencilla
Componente principal	Nueva variable resumen construida combinando las variables originales.
Dirección / vector propio	La “receta” de la componente: indica qué variables intervienen, con qué peso y en qué sentido.
Valor propio λ_k	Varianza de la componente k ; indica cuánta variabilidad de los datos captura esa receta.
Puntaje	Valor que obtiene una observación concreta en la nueva componente.
Varianza explicada	Proporción de la variabilidad total conservada por una componente.

Si una componente es

$$CP1 = 0.60X_1 + 0.58X_2 + 0.55X_3,$$

el vector propio $(0.60, 0.58, 0.55)$ contiene los pesos de la receta. Su valor propio es

$$\lambda_1 = \text{Var}(CP1),$$

y mide cuánto se diferencian las observaciones a lo largo de esa componente. Un valor propio grande indica que la componente ayuda a distinguir casos y que descartarla provocaría una pérdida importante de variabilidad.

La idea “variabilidad”

PCA supone que las direcciones donde más se diferencian las observaciones contienen información importante. La varianza de los *datos* no es automáticamente mala: sin variación, una variable no permite distinguir casos. Lo perjudicial es la varianza producida por ruido, errores de medición o atípicos. PCA no distingue por sí solo señal de ruido; por eso deben revisarse escala, calidad de datos, atípicos y significado de los pesos.

Sus objetivos son:

- reducir dimensión conservando la mayor cantidad posible de información;
- eliminar redundancia debida a correlaciones;
- facilitar visualización e interpretación de observaciones y variables;
- crear índices sintéticos;
- producir predictores incorrelados para técnicas posteriores, como regresión sobre componentes;
- detectar patrones, grupos y observaciones inusuales.

PCA es descriptivo y no supervisado. No garantiza que las componentes más variables sean las mejores para predecir una respuesta externa, porque esa respuesta no interviene en su construcción.

6.2. Idea geométrica

Primero se traslada el origen al centro de la nube mediante el centrado. Luego se rotan los ejes sin deformar la nube. El primer eje se orienta en la dirección de máxima variabilidad; el segundo, ortogonal al primero, captura la máxima variabilidad restante; el proceso continúa.

Para variables previamente centradas, la componente k tiene la forma

$$Y_k = \sum_{j=1}^p u_{jk}(X_j - \bar{X}_j),$$

donde los u_{jk} son pesos. No hace falta calcularlos en el parcial, pero sí leer cuáles tienen mayor valor absoluto y qué signos presentan.

Para la primera componente se resuelve conceptualmente

$$\max_{\mathbf{u}_1} \mathbf{u}_1' S \mathbf{u}_1 \quad \text{sujeto a} \quad \mathbf{u}_1' \mathbf{u}_1 = 1.$$

La solución satisface

$$S \mathbf{u}_1 = \lambda_1 \mathbf{u}_1.$$

Es decir, $\mathbf{u}_1$ es el vector propio asociado al mayor valor propio. Para las siguientes componentes se agrega ortogonalidad respecto de las anteriores. La restricción de norma uno impide aumentar artificialmente la varianza multiplicando todos los pesos por una constante.

6.3. Propiedades fundamentales

1. Hay como máximo tantas componentes como variables originales.
2. Las componentes están incorreladas entre sí.
3. La varianza de la componente k es su valor propio λ_k .
4. Los valores propios se ordenan $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$.
5. La suma de valores propios es la variabilidad total: $\sum_k \lambda_k = \text{traza}(S)$.
6. Si se usa la matriz de correlaciones, la variabilidad total es p .
7. La proporción explicada por CP_k es $\lambda_k / \sum_j \lambda_j$; las proporciones suman 1.
8. Conservar las q primeras componentes conserva la suma de sus proporciones explicadas.
9. La transformación completa no pierde información; la pérdida aparece al descartar componentes.

En forma matricial, si U reúne los vectores propios y $Y = X_c U$ contiene los puntajes,

$$\text{Cov}(Y) = U' S U = \Lambda.$$

Como Λ es diagonal, $\text{Cov}(Y_h, Y_k) = 0$ para $h \neq k$ y $\text{Var}(Y_k) = \lambda_k$. Esta salida resume simultáneamente la incorrelación y la varianza de las componentes.

Clave para el parcial

“Incorreladas” no significa necesariamente independientes. La independencia se deduce bajo condiciones adicionales, por ejemplo normalidad multivariada. Tampoco significa que las variables originales sean incorreladas.

6.4. Condiciones prácticas y alcance

El PCA descriptivo no exige normalidad multivariada. Sí requiere variables cuantitativas con relaciones que puedan resumirse linealmente, una matriz de covarianzas/correlaciones estimable y un tratamiento previo de faltantes. Variables constantes no aportan información y no pueden estandarizarse; colinealidades exactas producen valores propios nulos.

La técnica es sensible a atípicos porque utiliza medias, varianzas y covarianzas. Si las correlaciones son débiles y los valores propios resultan parecidos, habrá poca reducción posible: ninguna componente dominará claramente. La normalidad adquiere mayor importancia cuando se pretenden realizar inferencias probabilísticas, no para efectuar la descomposición algebraica en sí.

6.5. ¿Matriz de covarianzas o de correlaciones?

PCA sobre la **covarianza** deja que las variables más dispersas tengan mayor influencia. Es razonable si todas están en unidades comparables y esa mayor variabilidad representa realmente mayor importancia.

PCA sobre la **correlación** coloca inicialmente a todas las variables en una escala comparable. Equivale esencialmente a estandarizarlas: ninguna domina solo porque se mide en miles mientras otra se mide entre cero y uno.

Ejemplo de salida

En los datos empresariales sin estandarizar, los valores propios son aproximadamente

$$(39459.68, 39.90, 1.55, 1.13, 0.05, 0.03, 0),$$

y CP_1 parece explicar 99.9%. Esto no prueba que exista una dimensión económica casi perfecta: una variable de escala enorme domina la covarianza. Después de estandarizar, las proporciones

son

(0.303, 0.226, 0.147, 0.126, 0.119, 0.076, 0.003),

una representación mucho más equilibrada. La comparación revela un **problema de escala**.

6.6. Cómo leer las salidas de PCA

6.6.1. Valores propios y varianza explicada



El valor propio indica cuánta varianza captura una componente. La proporción de varianza explicada permite comparar componentes y la acumulada responde cuánta información retienen las primeras q .

Para el ejemplo estandarizado de siete variables:

	CP1	CP2	CP3	CP4	CP5	CP6	CP7
Valor propio	2.119	1.580	1.026	0.881	0.836	0.535	0.024
Explicada (%)	30.3	22.6	14.7	12.6	11.9	7.6	0.3
Acumulada (%)	30.3	52.9	67.6	80.2	92.1	99.7	100.0

Interpretaciones posibles:

- CP1 es la componente individual más informativa, pero solo resume 30.3 %; no alcanza por sí sola.
- Las dos primeras conservan 52.9 %. Un gráfico en dos dimensiones omite 47.1 %, por lo que debe interpretarse con cautela.
- Para superar 80 % se necesitan cuatro componentes; para superar 90 %, cinco.
- CP7 contiene apenas 0.3 %; probablemente representa una dirección casi redundante.
- La suma de los valores propios es 7, como debe ocurrir con siete variables estandarizadas.



Fuente: Cuaderno 3 IIA 2025, salidas de PCA con datos estandarizados.

El gráfico izquierdo muestra cuánto aporta cada componente por separado: las barras decrecen porque las componentes están ordenadas de mayor a menor varianza. El derecho va sumando esos aportes y por eso nunca disminuye. Para contestar una consigna, debe distinguirse entre “CP2 explica aproximadamente 22.6 %” y “CP1 más CP2 explican 52.9 %”.

6.6.2. Criterios para decidir cuántas componentes retener

No existe una regla universal. Deben combinarse criterio estadístico, simplicidad e interpretación.

- **Porcentaje acumulado:** conservar las necesarias para alcanzar un umbral razonable, por ejemplo 70 %, 80 % o 90 %, según el costo de perder información.
- **Gráfico de sedimentación (scree plot):** buscar el “codo”, a partir del cual los valores propios decrecen lentamente. Se conservan las anteriores al aplanamiento.
- **Kaiser:** en PCA sobre correlaciones, retener componentes con $\lambda > 1$, pues explican más que una variable estandarizada promedio. En el ejemplo sugeriría tres componentes y 67.6 % acumulado.
- **Interpretabilidad:** una solución ligeramente más grande puede preferirse si produce dimensiones sustantivamente claras.
- **Objetivo:** dos componentes pueden bastar para visualizar, pero no para reconstruir o modelar con poca pérdida.

Atención

El criterio de Kaiser no se traslada mecánicamente a PCA sobre covarianzas, porque “1” depende de las unidades. Un codo puede ser ambiguo. La respuesta correcta debe declarar el criterio y la pérdida aceptada.

6.6.3. Pesos, cargas y correlaciones variable–componente

Los **pesos** indican cuánto participa cada variable en la “receta” de una componente. Un número con valor absoluto grande tiene más presencia en esa receta; uno cercano a cero aporta poco. Variables con pesos del mismo signo empujan el puntaje hacia el mismo lado y signos opuestos forman un contraste. La salida *components* de los cuadernos muestra estos pesos. En otros programas, “cargas” puede significar específicamente correlaciones entre variables y componentes.

En la salida del cuaderno:


$$CP1 \approx 0.657 \text{Cashvent} + 0.662 \text{Benvent} - 0.311 \text{Benrecpr} + \dots$$

CP1 contrapone principalmente Cashvent y Benvent (lado positivo) con Benrecpr (lado negativo). Un individuo con puntaje alto en CP1 tenderá a presentar valores altos en las dos primeras y bajo en la última, siempre interpretando las variables en su definición económica.

$$CP2 \approx 0.658 \text{Ventact} + 0.389 \text{Ventplan} - 0.621 \text{Inmoactt} + \dots$$

CP2 contrasta ventas actuales/planificadas con inmovilizado sobre activo. Un puntaje alto se asocia al primer perfil; uno bajo, al perfil opuesto.

Cuando la matriz de pesos se presenta como mapa de calor, el color codifica signo y magnitud. Deben buscarse bloques de colores intensos por fila: identifican las variables que definen cada componente. Un color neutro indica coeficiente cercano a cero. La escala lateral es indispensable, porque colores similares pueden representar rangos diferentes entre gráficos.



Fuente: Cuaderno 3 IIA 2025, matriz de pesos de las componentes.

Cada **fila** corresponde a una componente y cada **columna** a una variable original. Los colores amarillos señalan pesos positivos altos, los violetas pesos negativos y los verdes valores cercanos a cero, de acuerdo con la escala lateral. Para interpretar CP1 se recorre su fila y se localizan las celdas de mayor intensidad absoluta; después se traduce la combinación de signos al significado de las variables.

Atención

El signo global de una componente es arbitrario: multiplicar todos sus pesos y puntajes por -1 representa exactamente el mismo eje. Importan los valores absolutos y las relaciones de signos dentro de la componente, no que una versión particular aparezca “positiva”.

Los **pesos del vector propio** y las **correlaciones variable–componente** están relacionados, pero no siempre son numéricamente idénticos. Antes de interpretar una tabla debe leerse su título: “components”, “loadings”, “correlations” o “contributions” pueden representar objetos diferentes.

Si PCA se calcula sobre una matriz de covarianzas, la correlación entre la variable X_j y la componente Y_k es

$$\text{Corr}(X_j, Y_k) = \frac{\sqrt{\lambda_k} u_{jk}}{\sqrt{s_{jj}}}.$$

Para variables estandarizadas, $s_{jj} = 1$, por lo que la correlación es $\sqrt{\lambda_k} u_{jk}$. De aquí surge una distinción útil:

- **peso** u_{jk} : coeficiente utilizado para construir el puntaje;
- **carga/correlación**: grado en que la variable queda asociada a la componente;
- **carga al cuadrado**: parte de la variación de una variable que puede verse en una componente, cuando la carga se define como correlación;
- **comunalidad en q componentes**: parte total de una variable que queda resumida por las primeras q componentes; es la suma de sus cargas al cuadrado;
- **contribución**: cuánto ayudó una variable a orientar o construir un eje en comparación con las demás; depende de la normalización usada por la salida.

Una variable puede contribuir fuertemente a CP3 y quedar mal representada en el plano CP1–CP2. Por ello, una flecha corta no siempre significa que la variable sea irrelevante en el análisis completo: puede estar principalmente asociada con componentes no graficadas.

6.6.4. Puntajes de las observaciones

Los **puntajes** son la nueva ubicación de cada observación después de cambiar los ejes originales por las componentes. Un puntaje alto y positivo indica que el caso se parece al perfil positivo definido por los pesos; uno muy negativo se parece al perfil contrario. Un puntaje cercano a cero ubica al caso cerca del promedio en esa dimensión.

Dos observaciones cercanas en el espacio de las componentes retenidas tienen perfiles parecidos en la información representada. Si se retuvo poca varianza, podrían diferir en componentes omitidas.

Si U contiene todos los vectores propios, los puntajes completos son $Y = X_c U$. Al conservar solo q componentes, la reconstrucción aproximada es

$$\hat{X}_c = Y_q U_q'$$

La diferencia $X_c - \hat{X}_c$ es la información descartada. PCA posee una propiedad óptima: entre todas las aproximaciones lineales de dimensión q , las primeras q componentes minimizan el error cuadrático de reconstrucción.

Un puntaje extremo puede identificar un caso inusual sobre una dirección de alta variación. Sin embargo, una observación también puede ser atípica en componentes finales de baja varianza. Por eso un gráfico CP1–CP2 no sustituye un análisis multivariado completo de atípicos.


6.6.5. Biplot

El **biplot** es un mapa que coloca en el mismo plano a las observaciones y a las variables. Los puntos muestran casos y las flechas señalan hacia dónde aumenta cada variable, normalmente usando CP1 y CP2.

- Flecha larga: variable bien representada o con relación fuerte con el plano, según el escalamiento utilizado.
- Flechas con ángulo pequeño: correlación positiva.
- Flechas en sentidos opuestos: correlación negativa.
- Flechas aproximadamente perpendiculares: correlación lineal cercana a cero.
- Punto proyectado en el sentido de una flecha: valor relativamente alto en esa variable; en sentido contrario, bajo.
- Puntos próximos: observaciones similares en el plano; puntos alejados del origen: perfiles más extremos.

Atención

Estas lecturas son aproximadas y dependen de que CP1 y CP2 expliquen suficiente varianza. La longitud y los ángulos también dependen del escalamiento del biplot. No interpretar distancias o ángulos como exactos sin conocer la construcción.



Fuente: Cuaderno 3 IIA 2025, biplot de observaciones y variables.

En esta salida, las flechas de Cashvent y Benvent apuntan casi en la misma dirección, coherentemente con su fuerte correlación positiva. Inmoactt se orienta principalmente en sentido contrario a Ventact sobre PC2. La nube concentrada cerca del origen reúne observaciones de perfil relativamente medio en el plano, mientras que los puntos alejados merecen revisión. La interpretación debe recordar que el plano representa solo las dos primeras componentes.

6.6.6. Calidad de representación en un plano

Para una variable o una observación, el **coseno cuadrado** ($\cos^2$) indica cuánto de ese elemento logra verse en el gráfico elegido. Un $\cos^2$ alto en CP1–CP2 significa que el plano muestra bien su posición; uno bajo indica que una parte importante quedó en componentes no dibujadas. No debe confundirse con la contribución: calidad pregunta “¿qué tan bien se ve este elemento?”, mientras contribución pregunta “¿cuánto ayudó a construir el eje?”.

En un círculo de correlaciones, variables cerca de la circunferencia están bien representadas por el plano. Variables cerca del origen tienen correlaciones pequeñas con ambas componentes y no deben interpretarse fuertemente a partir de ese gráfico.

6.7. Usos complementarios

Índice sintético: si las variables miden aspectos de un mismo fenómeno, una componente puede emplearse como índice. Debe explicar suficiente variación y tener una interpretación coherente; su orientación de signo puede invertirse para que “más” signifique lo deseado.

Para construirlo se seleccionan variables pertinentes, se decide si estandarizar, se obtiene la componente y se interpreta el patrón de cargas. Que CP1 explique la mayor varianza no basta: si combina variables conceptualmente incompatibles o presenta cargas difíciles de justificar, el índice puede carecer de validez sustantiva. Los puntajes permiten ordenar observaciones, pero son relativos a la muestra, variables y período analizados.

Regresión sobre componentes principales: reemplaza predictores correlacionados por componentes incorreladas. Ayuda frente a multicolinealidad y reduce dimensión. Sin embargo, las componentes se eligen por varianza de los predictores y no por asociación con la respuesta; una componente de baja varianza podría ser predictivamente útil.

Si $Y = X\beta + \varepsilon$ y $X_c = ZU'$, la regresión puede formularse usando algunas columnas de puntajes Z_q

en lugar de todas las variables originales. La estabilidad mejora porque los nuevos predictores son ortogonales, pero los coeficientes quedan menos directamente ligados a cada variable original. Para interpretar el modelo en la escala original deben combinarse los coeficientes de regresión con los pesos de las componentes.

Clave para el parcial

PCA soluciona la multicolinealidad algebraicamente, no demuestra que los predictores sean causalmente válidos. Tampoco debe elegirse la cantidad de componentes únicamente por varianza explicada si el objetivo final es predecir una respuesta.

6.8. Errores frecuentes en PCA

- Concluir que CP1 es “la variable más importante”: es una combinación de variables.
- Confundir varianza explicada individual con acumulada.
- Elegir dos componentes solo porque pueden graficarse.
- Ignorar escala, faltantes o atípicos antes del análisis.
- Interpretar coeficientes pequeños con el mismo peso que los grandes.
- Creer que cargas opuestas implican causalidad negativa.
- Comparar signos de componentes entre ejecuciones sin considerar la indeterminación de signo.
- Usar el gráfico para afirmar separación perfecta cuando el plano explica poca variación.

7. Análisis de conglomerados o clustering

7.1. Objetivo y lógica general


Definición

El análisis de conglomerados intenta ordenar las observaciones en grupos naturales: casos que se parecen quedan juntos y casos diferentes quedan separados. El método no conoce previamente los grupos; los construye a partir de las variables y de la forma elegida para medir semejanza.

No descubre necesariamente “clases verdaderas”. La solución depende de variables, escalamiento, distancia, algoritmo, tratamiento de atípicos y número de grupos. Un cluster recibe significado recién después de describir su perfil.

7.2. Familias de algoritmos de clustering

Algoritmos para la formación de clusters



Fuente: Machine learning, diapositiva “Algoritmos para la formación de clusters”.

La primera decisión es distinguir dos grandes familias:

- **Métodos jerárquicos:** producen una secuencia de agrupamientos anidados y pueden representarse mediante un dendrograma. Una vez realizada una fusión o división, normalmente no se revierte.
- **Métodos no jerárquicos:** construyen directamente una partición. En K-means debe fijarse previamente el número K de grupos y las observaciones pueden cambiar de cluster durante las iteraciones.

Los métodos jerárquicos se subdividen en:

- **Aglomerativos:** comienzan con una observación por grupo y fusionan grupos progresivamente. Son los utilizados principalmente en la materia.
- **Divisivos:** comienzan con todas las observaciones juntas y separan el conjunto de manera progresiva.

Dentro de los aglomerativos, el diagrama distingue:

- **Ward:** fusiona los grupos que producen el menor aumento de heterogeneidad interna.
- **Centroide:** compara los vectores de medias de los grupos.
- **Ligamiento:** define la distancia entre grupos mediante distancias entre sus observaciones. Puede ser simple —par más cercano—, completo —par más lejano— o promedio —promedio de todos los pares cruzados—.

Entre los no jerárquicos, el material desarrolla **K-means**, que alterna asignación al centroide más cercano y actualización de centroides hasta estabilizarse.

Cómo reconocer la familia en una salida

Un dendrograma, un historial de fusiones o términos como Ward, enlace simple y enlace completo indican clustering jerárquico aglomerativo. Una salida con centroides iterativos, etiquetas de K-means, inercia o elección previa de K corresponde a un método no jerárquico.

La variabilidad total puede descomponerse conceptualmente en

$$T = W + B,$$

donde W es variabilidad dentro de los grupos y B entre grupos. Una buena partición pretende W pequeña y B grande, sin crear tantos grupos que cada observación termine aislada.

En forma matricial, si $\bar{\mathbf{x}}_g$ es el centroide del grupo g y $\bar{\mathbf{x}}$ el centroide general,

$$T = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})',$$

$$W = \sum_{g=1}^K \sum_{i \in g} (\mathbf{x}_i - \bar{\mathbf{x}}_g)(\mathbf{x}_i - \bar{\mathbf{x}}_g)', \quad B = \sum_{g=1}^K n_g (\bar{\mathbf{x}}_g - \bar{\mathbf{x}})(\bar{\mathbf{x}}_g - \bar{\mathbf{x}})'.$$

Las trazas de estas matrices resumen las sumas de cuadrados totales, dentro y entre grupos. Esta descomposición fundamenta Ward, K-means, R^2 y Calinski–Harabasz.

7.3. Antes de agrupar

1. Definir unidad de análisis y objetivo.
2. Elegir variables pertinentes; variables irrelevantes añaden ruido y variables redundantes pueden sobreponderar un concepto.
3. Revisar tipos, faltantes, distribuciones y atípicos.
4. Estandarizar si las escalas no son comparables.
5. Elegir una distancia compatible con los tipos de variables.
6. Elegir método y evaluar varias cantidades de grupos.
7. Perfilar, validar y comunicar la solución.

Clave para el parcial

Si los clusters cambian mucho entre base original y estandarizada, la escala estaba influyendo. Si cambian mucho al retirar pocos atípicos, la solución es sensible y debe reportarse; no alcanza con elegir el gráfico “más lindo”.

El clustering exploratorio no requiere normalidad ni una variable respuesta. Sin embargo, cada método presupone implícitamente una geometría: K-means y Ward privilegian distancias cuadráticas y grupos compactos; el enlace simple admite formas alargadas. Por eso “no tener supuestos distribucionales” no significa que la elección del algoritmo sea neutral.

7.4. Proximidad según el tipo de variable

Para variables métricas se usan distancias como euclídea o Manhattan. Para variables binarias, dos observaciones pueden resumirse mediante cuatro conteos: a (presencia en ambas), b y c (desacuerdos) y d (ausencia en ambas). Si presencia y ausencia son igualmente informativas, puede usarse el coeficiente de coincidencia simple

$$s_{SM} = \frac{a + d}{a + b + c + d}.$$

Si la presencia es rara e importante y la doble ausencia no aporta similitud, se prefiere Jaccard:

$$s_J = \frac{a}{a + b + c}.$$

Un valor alto indica mayor similitud. La disimilitud correspondiente puede definirse como $1 - s$.

La distancia de Gower permite responder “¿qué tan parecidos son estos dos casos?” aunque algunas variables sean numéricas y otras categóricas. Compara cada característica con una regla adecuada a su tipo, lleva todas las comparaciones a una escala común y luego las promedia. Así evita tratar códigos nominales como si fueran cantidades. También puede ignorar, para cada par, las variables que estén ausentes.

Atención

Codificar categorías como 1, 2 y 3 y aplicar distancia euclídea supone orden e intervalos iguales. Esto es inválido para una variable nominal y puede ser discutible para una ordinal. La medida debe respetar el nivel de medición.

7.5. Clustering jerárquico aglomerativo

El clustering jerárquico puede imaginarse como armar un árbol desde las hojas. Al principio cada observación está sola; luego se unen los dos grupos más parecidos, se repite el proceso y finalmente todos quedan conectados. Una unión realizada no se deshace. Para decidir qué unir se necesita una distancia entre observaciones y una regla para comparar grupos.

En cada etapa hay una partición C_m y una cantidad de grupos decreciente. El algoritmo es determinista si la matriz de distancias y las reglas para resolver empates están fijadas. A diferencia de K-means, no necesita centroides aleatorios, pero puede ser computacionalmente pesado en bases muy grandes porque trabaja con muchas distancias.

7.5.1. Criterios de enlace

La distancia elegida —por ejemplo, la euclídea— permite comparar *dos observaciones*. Sin embargo, después de las primeras fusiones cada conglomerado contiene varias observaciones. El **criterio de enlace** responde entonces: *¿cómo se resumen todas las distancias entre los miembros de dos grupos en una sola medida para decidir si conviene unirlos?*

Método	Pregunta que se hace	Consecuencia habitual
Vecino más cercano (simple)	¿Cuál es el par más cercano, tomando un miembro de cada grupo? Solo importa esa distancia mínima.	Basta que existan dos puntos cercanos para considerar cercanos a los grupos. Puede unirlos mediante “puentes” y formar cadenas alargadas.
Vecino más lejano (completo)	¿Cuál es el par más separado, tomando un miembro de cada grupo? Se usa esa distancia máxima.	Los grupos se consideran cercanos solo si ni siquiera sus miembros más alejados están demasiado lejos. Favorece grupos compactos, aunque un extremo puede aumentar mucho la distancia.
Promedio	En promedio, ¿qué tan separados están todos los pares formados con un miembro de cada grupo?	Considera toda la información cruzada y suele dar una solución intermedia entre simple y completo.
Centroide	¿Qué distancia existe entre el centro o perfil medio de un grupo y el del otro?	Compara representantes centrales, pero puede ocultar la dispersión interna y producir inversiones en las alturas del dendrograma.
Ward	Si se unieran los dos grupos, ¿cuánto aumentaría la variabilidad dentro del nuevo grupo?	Elige la fusión que menos empeora la homogeneidad interna. Suele producir grupos compactos y relativamente esféricos; se vincula naturalmente con la distancia euclídea.

Un mismo par de grupos, tres lecturas

Supóngase que las distancias entre todos los pares cruzados de los grupos A y B son 2, 4, 5 y 9.

- **Enlace simple:** toma la menor, por lo que $d(A, B) = 2$. Concluye que los grupos están cerca porque existe al menos un par cercano.

- **Enlace completo:** toma la mayor, por lo que $d(A, B) = 9$. Es más exigente: advierte que hay miembros de ambos grupos muy separados.
- **Enlace promedio:** usa $(2 + 4 + 5 + 9)/4 = 5$. Resume la separación general sin quedarse con un solo extremo.

No hay una contradicción: cada método usa una definición distinta de “grupos cercanos”. El centroide necesitaría conocer las medias de los grupos, mientras que Ward compararía la variabilidad interna antes y después de fusionarlos.

Formalmente, para grupos C_1 y C_2 :

$$d_{simple}(C_1, C_2) = \min_{i \in C_1, j \in C_2} d(i, j),$$

$$d_{completo}(C_1, C_2) = \max_{i \in C_1, j \in C_2} d(i, j),$$

$$d_{promedio}(C_1, C_2) = \frac{1}{n_1 n_2} \sum_{i \in C_1} \sum_{j \in C_2} d(i, j).$$

Ward no define proximidad por un único par de puntos, sino por el incremento de suma de cuadrados dentro:

$$I(C_1, C_2) = W_{C_1 \cup C_2} - W_{C_1} - W_{C_2}.$$

Aquí W_C denota la suma de cuadrados interna escalar del grupo C . Se fusiona el par con menor incremento. Por ello una gran altura final bajo Ward indica que unir esos grupos deteriora mucho la homogeneidad interna.

Regla para recordarlos

Simple mira el **mejor caso** (el par más cercano); completo, el **peor caso** (el par más lejano); promedio, **todos los pares**; centroide, **los centros**; y Ward, **cuánto empeora la homogeneidad** al fusionar.

7.5.2. Dendrograma e historial de aglomeración

El **dendrograma** es el dibujo de ese árbol. Las hojas inferiores son las observaciones, las uniones muestran cuándo se formaron grupos y la altura indica cuánta diferencia hubo que aceptar para unirlos. Una línea horizontal de corte produce tantos clusters como ramas principales atraviesa.


Una gran diferencia de altura entre fusiones consecutivas sugiere cortar antes del salto: la siguiente unión combinaría grupos muy distintos. Cortar más abajo genera más grupos; cortar más arriba, menos. El orden horizontal de las hojas puede rotarse dentro de ramas y no debe interpretarse como distancia ordinaria.

Las alturas de dendrogramas contruidos con bases originales, estandarizadas o filtradas no siempre son directamente comparables: cambiar la escala cambia toda la matriz de distancias. La comparación relevante es la estructura relativa de fusiones, la estabilidad de los grupos y el criterio de validación calculado en cada representación.

En un historial de aglomeración, números negativos suelen identificar observaciones originales y positivos, conglomerados formados en etapas anteriores. La columna de altura muestra la distancia o costo de la fusión.

Historial de Conglomeración

	height	merge.1	merge.2
1	13	-3	-4
2	29	-7	-8
3	32	-1	-2
4	50	-5	-6
5	141	1	3
6	182	2	4
7	1227	5	6



Donde:

- *height* es un índice que refleja la distancia en la que se fueron generando las agrupaciones.
- *merge.1* y *merge.2* son los grupos que se fueron fusionando en cada etapa del proceso.

Fuente: Machine learning, historial y dendrograma del ejemplo de ocho empresas.

La tabla y el árbol cuentan el mismo proceso. Las primeras filas muestran fusiones de observaciones originales: E3–E4 a altura 13, E7–E8 a 29 y E1–E2 a 32. Más adelante se unen los grupos ya formados. El salto de 182 a 1227 es muy grande; cortar antes de la última fusión deja dos conglomerados principales, $\{E1, E2, E3, E4\}$ y $\{E5, E6, E7, E8\}$. La posición izquierda–derecha de las hojas no representa una escala; lo importante es la altura de las uniones.

La **distancia ultramétrica** c_{ij} es la altura del árbol en la que dos observaciones se encuentran por primera vez dentro del mismo grupo. Es la distancia que el dendrograma les atribuye, no necesariamente su distancia original. El conjunto de estas alturas forma la matriz cofenética C .

7.5.3. Correlación cofenética

La **correlación cofenética** pregunta cuánto respeta el árbol las distancias originales. Compara la separación real de cada par con la altura a la que el dendrograma los une. Un valor cercano a 1 significa que el árbol deformó poco las relaciones entre casos. Sirve para comparar enlaces, pero no garantiza grupos útiles ni decide por sí sola dónde cortar.

Si d_{ij} son distancias originales y c_{ij} las cofenéticas, el coeficiente es la correlación de Pearson entre ambos conjuntos:

$$r_{cof} = \text{Corr}(\{d_{ij} : i < j\}, \{c_{ij} : i < j\}).$$

Debe compararse entre dendrogramas contruidos sobre la misma matriz de distancias. Un valor mayor indica menor distorsión global, pero un método con buen ajuste cofenético puede no ofrecer la partición más interpretable para el objetivo aplicado.

7.6. K-means

K-means coloca K centros y reparte cada observación al centro más cercano. Después mueve cada centro al promedio de los casos asignados y repite hasta estabilizarse. Su objetivo es que los casos queden lo más cerca posible del centro de su propio grupo.

Su función objetivo es

$$W(K) = \sum_{g=1}^K \sum_{i \in C_g} \|\mathbf{x}_i - \boldsymbol{\mu}_g\|^2,$$

donde $\boldsymbol{\mu}_g$ es el vector de medias del grupo g . Dado que usa medias y distancias cuadráticas, una observación extrema puede desplazar fuertemente un centroide.

El **centroide** es el “perfil promedio” del grupo: contiene la media de cada variable. No tiene que coincidir con una observación real. Leer un centroide consiste en comparar sus valores con los otros grupos o con el promedio general y traducir ese patrón al problema.

Procedimiento conceptual:

1. elegir K centroides iniciales;
2. asignar cada caso al centroide más cercano;
3. recalcular cada centroide como media del grupo;
4. repetir hasta que las asignaciones o centroides se estabilicen.

Fortalezas: simple, rápido y escalable. Limitaciones: depende de inicialización, escala y atípicos; funciona mejor con grupos compactos, aproximadamente esféricos y de tamaños/dispersiones no demasiado diferentes. Solo usa naturalmente variables cuantitativas y medias.


Distintas inicializaciones pueden llevar a mínimos locales; por eso se realizan varios inicios y se conserva la solución con menor inercia. Los números asignados a clusters no tienen orden ni significado intrínseco.

El algoritmo converge cuando ya no cambian las asignaciones, los centroides apenas se mueven o se alcanza un máximo de iteraciones. Convergencia no significa haber encontrado la mejor solución global: solo una solución estable para esa inicialización. Tampoco significa que el K elegido sea correcto.

7.7. Elegir el número de clusters

7.7.1. Inercia y método del codo

La **inercia** resume cuánto se alejan los casos del centro de su grupo. Una inercia baja significa grupos compactos. Siempre disminuye al aumentar K y llega a cero si cada caso forma su propio grupo; por eso no se elige simplemente el menor valor. El método del codo busca el punto a partir del cual crear más grupos aporta poca mejora adicional.



Fuente: Cuaderno 4 IIA 2025, curva del codo para Online Retail.

En la curva se observa una caída intensa al pasar a dos y tres clusters y mejoras cada vez menores después. Por eso $K = 3$ aparece como candidato razonable. No es una demostración automática: si

la curva no tiene un quiebre nítido, deben compararse silueta, estabilidad, tamaños y utilidad de los perfiles.

7.7.2. Coeficiente R^2 y descomposición de variabilidad

$$R^2 = 1 - \frac{\text{traza}(W)}{\text{traza}(T)} = \frac{\text{traza}(B)}{\text{traza}(T)}.$$

El R^2 de clustering responde: “¿qué proporción de las diferencias totales queda explicada por separar los casos en estos grupos?”. Un valor alto indica que buena parte de la variación se encuentra entre clusters y no dentro de ellos. Si la bibliografía usa W , B y T como sumas de cuadrados, la fórmula abreviada es $R^2 = 1 - W/T = B/T$. El valor aumenta automáticamente con K , por lo que debe buscarse una mejora importante sin crear grupos innecesarios.

Atención

Si la fórmula usada es $R^2 = 1 - W/T$, se busca **maximizar** R^2 ; lo que se busca minimizar es W/T . La frase “buscar R^2 pequeño” contradice esa fórmula. Además, no se divide una matriz por otra: se emplean sus trazas o las sumas de cuadrados escalares equivalentes.

El criterio de Hartigan evalúa la reducción relativa de W al pasar de g a $g + 1$ grupos; en la bibliografía se sugiere introducir uno más si $F > 10$. Calinski–Harabasz compara dispersión entre y dentro ajustando por cantidad de grupos; se prefiere el valor **más alto**.

Las expresiones presentadas en la bibliografía son

$$F_g = \frac{W_g - W_{g+1}}{W_{g+1}/(n - g - 1)}, \quad CH(g) = \frac{\text{traza}(B)}{\text{traza}(W)} \frac{n - g}{g - 1}.$$

Hartigan pregunta si agregar un grupo reduce W lo suficiente; Calinski–Harabasz premia separación entre grupos y penaliza dispersión interna y complejidad. Sus escalas no son porcentajes y solo son comparables entre soluciones construidas sobre los mismos datos y variables.

7.7.3. Silueta

La **silueta** compara dos ideas para cada caso: qué tan cerca está de su propio grupo y qué tan cerca estaría del grupo alternativo más próximo. Si a_i es la distancia media al grupo propio y b_i la distancia media al grupo vecino más cercano, entonces

$$s_i = \frac{b_i - a_i}{\max(a_i, b_i)}, \quad -1 \leq s_i \leq 1.$$

La calidad global se resume promediando todos los casos:

$$SC = \frac{1}{n} \sum_{i=1}^n s_i.$$

- Cerca de 1: caso bien ubicado y separado.
- Cerca de 0: caso fronterizo entre dos grupos.
- Negativo: podría encajar mejor en otro grupo.

La silueta promedio compara cantidades de grupos, distancias o métodos: mayor es mejor. Según la escala usada en el material: 0.71–1 estructura fuerte; 0.51–0.70 razonable; 0.26–0.50 débil y posiblemente artificial; menor de 0.25 sin estructura sustancial. Son orientaciones, no leyes universales.

En un **gráfico de siluetas**, cada barra horizontal representa el s_i de un caso y suele agruparse por cluster. Grupos con muchas barras negativas muestran asignaciones problemáticas; barras consistentemente largas indican buena cohesión. Una línea vertical marca el promedio global. Además del promedio, deben observarse clusters particularmente débiles y tamaños muy desiguales.

Ejemplo de salida

En Online Retail, las siluetas para $K = 2, \dots, 8$ son aproximadamente 0.410, 0.514, 0.488, 0.470, 0.452, 0.315 y 0.404. El máximo corresponde a $K = 3$; por esta métrica se eligen tres grupos y la estructura es apenas razonable. No es una separación perfecta.

7.8. Comparar dos particiones

Matriz de contingencia o “confusión”: cruza las asignaciones de dos métodos. Concentración en pocas correspondencias indica acuerdo, pero la diagonal solo es interpretable después de alinear etiquetas, porque el cluster 0 de un método puede corresponder al 2 del otro.

ARI, índice Rand ajustado: comprueba si dos métodos tienden a mantener juntos y separados a los mismos pares de casos. Descuenta las coincidencias que aparecerían por azar y no depende del número usado para nombrar cada cluster. Cerca de 1 indica particiones iguales; cerca de 0, acuerdo similar al azar; puede ser negativo si el acuerdo es peor que el esperado.

AMI, información mutua ajustada: pregunta cuánto ayuda conocer el grupo asignado por un método para adivinar el grupo asignado por el otro. También descuenta el acuerdo esperado por azar. Cerca de 1 indica gran coincidencia; cerca de 0, poca información compartida.

Ejemplo de salida

El cuaderno informa $ARI = 0.660$ y $AMI = 0.647$ entre jerárquico y K-means con tres grupos. Hay acuerdo apreciable, pero no identidad. Las siluetas son 0.457 para jerárquico y 0.514 para K-means; bajo el mismo espacio y distancia, K-means produce la separación interna algo mejor.

ARI y AMI comparan *acuerdo entre particiones*; silueta evalúa *cohesión y separación respecto de los datos*. Dos métodos pueden concordar mucho y ambos formar grupos pobres, o discrepar aunque uno tenga buena silueta.

7.8.1. Validez interna, externa y estabilidad

La **validación interna** pregunta si los grupos son compactos y están separados usando solamente los datos y la partición; ejemplos: silueta, W y Calinski–Harabasz. La **validación externa** compara la solución con una clasificación de referencia o con otro método; ejemplos: matriz de contingencia, ARI y AMI. Si no existen etiquetas verdaderas, comparar dos algoritmos mide concordancia, no exactitud.

La **estabilidad** estudia si la solución se conserva al cambiar la muestra, inicialización o pequeñas decisiones de preprocesamiento. Puede evaluarse repitiendo K-means, remuestreando casos o comparando soluciones con/sin atípicos. Un índice interno alto acompañado de gran inestabilidad exige cautela.

La utilidad final también es sustantiva: los grupos deben ser suficientemente diferentes, tener tamaño razonable y permitir una interpretación o acción. Un criterio matemático no reemplaza el conocimiento del problema.

7.9. Del registro transaccional a la base RFM

El caso Online Retail muestra una transformación conceptual importante. La base inicial posee 541 909 filas y ocho variables; cada fila corresponde a un artículo dentro de una factura. *InvoiceNo*, *StockCode*, descripción, cantidad, fecha, precio, cliente y país no constituyen todavía una base adecuada para segmentar clientes.

La variable monetaria por renglón se construye como

$$\text{Gasto}_{\text{renglón}} = \text{Cantidad} \times \text{Precio unitario}.$$

Después se agrupa por cliente:

$$M_i = \sum_{t \in i} \text{Gasto}_t, \quad F_i = \#\{\text{registros o compras de } i\}, \quad R_i = \text{Fecha}_{\text{referencia}} - \max_t(\text{Fecha}_{it}).$$

M es valor monetario, F frecuencia y R recencia expresada en días. Debe verificarse qué se contó para frecuencia: renglones, facturas únicas o compras. Contar renglones puede otorgar mayor frecuencia a quien compra muchos productos en una misma factura; contar facturas mide eventos de compra.

La salida muestra 406 829 identificadores de cliente no faltantes sobre 541 909 registros. Al eliminar faltantes quedan 406 829 filas y luego, al agrupar, 4 372 clientes. Esta reducción no es pérdida accidental: cambia deliberadamente la granularidad de transacción a cliente. Sin embargo, eliminar todos los registros sin identificador sí excluye ventas y puede sesgar la población analizada.

Los mínimos negativos de cantidad y precio, y facturas cuyo código comienza con “C”, pueden representar cancelaciones o devoluciones. Si se suman compras y devoluciones, un gasto neto cero puede ser legítimo. Si el objetivo fuera medir compras brutas, deberían tratarse de otra manera. La limpieza depende de la definición comercial del indicador.

Clave para el parcial

Una salida con `CustomerID` numérico no convierte al identificador en variable cuantitativa: sigue siendo nominal. No debe estandarizarse ni incluirse en una distancia. Su función es identificar y agrupar filas.

7.10. Perfilar y nombrar clusters

Después de asignar grupos se calculan tamaños, medias/medianas y gráficos por cluster. El perfil se construye comparando cada centroide con la media general o con otros grupos. Conviene considerar dispersión interna además de la media: dos grupos con igual media pueden tener heterogeneidad distinta.

En la segmentación RFM del cuaderno se utilizan:

- **Gasto (monetary)**: total comprado; más alto suele ser comercialmente favorable.
- **Frecuencia**: cantidad de transacciones; más alto indica compra frecuente.
- **Días (recency)**: días desde la última compra; **más bajo es mejor** porque significa compra reciente.


Para K-means con tres clusters, las medias son:

Cluster	Gasto	Frecuencia	Días
0	1015.15	62.13	43.50
1	392.06	25.46	243.41
2	5646.85	301.27	20.25

Los tamaños informados son 2 774, 1 060 y 449 clientes. La desigualdad de tamaños no invalida automáticamente la solución: puede reflejar segmentos reales. Sin embargo, un grupo muy pequeño exige comprobar si corresponde a un nicho estable o a observaciones extremas que arrastraron un centroide.

Interpretación:

- Cluster 2: alto gasto, altísima frecuencia y compra muy reciente; clientes de mayor valor o leales.
- Cluster 1: bajo gasto y frecuencia, con compra lejana; clientes inactivos o de bajo valor.
- Cluster 0: nivel intermedio, relativamente recientes; clientes regulares con potencial.



Fuente: Cuaderno 4 IIA 2025, distribución de las variables RFM por cluster.

Los gráficos confirman que el perfil no debe construirse solo con centroides. El cluster 2 se distingue por gasto y frecuencia elevados; el cluster 1 por una recencia mucho peor, es decir, más días desde la última compra. Las cajas, brazos y puntos externos muestran además la heterogeneidad dentro de cada grupo. Una diferencia de medias puede ser clara aunque todavía exista superposición entre distribuciones.

Atención

El texto de un cuaderno puede usar otra numeración por una ejecución diferente. Esto no es contradicción: K-means puede permutar las etiquetas. El perfil se identifica por sus medias, no por memorizar “cluster 1 = mejores clientes”.

7.11. PCA y clustering juntos

PCA puede visualizar clusters en dos dimensiones, reducir ruido o evitar redundancia antes de agrupar. Sin embargo:

- un gráfico PCA es una proyección; superposición en CP1–CP2 no prueba que los grupos sean iguales en dimensiones omitidas;
- separación visual puede exagerarse si no se informa varianza explicada;
- agrupar sobre componentes cambia el peso de la información; debe declararse cuántas se conservaron;
- PCA maximiza varianza global, no separación de clusters.

7.12. Errores frecuentes en clustering

- Interpretar los números de cluster como orden o categoría real.
- Elegir K por un único criterio sin revisar perfiles y estabilidad.
- Decir que menor silueta es mejor.
- Elegir la menor inercia sin penalizar más grupos.
- Aplicar K-means a variables sin escalar o a categorías codificadas arbitrariamente.
- Ignorar que atípicos pueden convertirse en centroides o ramas aisladas.
- Leer distancia horizontal en un dendrograma; la información relevante de fusión está en la altura.
- Confundir acuerdo entre métodos con calidad verdadera.
- Nombrar grupos sin describir variables originales.

8. Salidas de Colab: guía sistemática de interpretación

Esta sección concentra las salidas con mayor probabilidad de aparecer en un examen orientado a interpretación. Frente a cualquier resultado conviene responder: *qué objeto muestra, qué patrón numérico destaca, qué significa en el problema y qué limitación debe recordarse*. No es necesario reconstruir el código que produjo la salida.

8.1. Salida descriptiva tipo *describe*

Una tabla con count, mean, std, min, 25 %, 50 %, 75 % y max se lee así:

1. **count**: casos válidos; diferencias entre columnas revelan faltantes.
2. **mean y 50 %**: su diferencia sugiere asimetría.
3. **std**: dispersión absoluta.
4. **25 %, 75 %**: delimitan el 50 % central; su diferencia es RI.
5. **min/max frente a cuartiles**: extremos muy alejados sugieren atípicos o colas largas.

Respuesta modelo

La variable presenta 224 datos válidos. La media supera claramente la mediana, lo que sugiere asimetría derecha. El máximo se aleja mucho de Q_3 , por lo que conviene revisar extremos mediante boxplot. El desvío debe interpretarse en la unidad original y no permite por sí solo comparar con otra variable de escala distinta.

Salida de Colab

```
retail.shape → (541909, 8)
Description: 540455 non-null
CustomerID: 406829 non-null
Quantity: min = -80995, max = 80995
UnitPrice: min = -11062.06, max = 38970.00
```

Esta combinación de `shape`, `info()` y `describe()` permite concluir que hay 541 909 registros y ocho columnas; `CustomerID` posee muchos faltantes; y existen cantidades y precios negativos que requieren investigación. No corresponde afirmar automáticamente que son errores: pueden representar cancelaciones, devoluciones o ajustes. Tampoco debe incluirse `CustomerID` como variable cuantitativa solo porque aparezca almacenada como número.

8.2. Matriz de correlaciones

Buscar pares con mayor $|r|$, indicar dirección y fuerza, y advertir redundancia. La diagonal no aporta asociaciones: siempre vale 1. Como la matriz es simétrica, cada relación aparece dos veces.

Definición matemática que conviene conocer

El coeficiente de correlación lineal de Pearson es la covarianza dividida por los desvíos estándar:

$$r_{XY} = \frac{\text{Cov}(X, Y)}{s_X s_Y} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}.$$

El reescalamiento elimina las unidades y obliga a que $-1 \leq r \leq 1$. En una respuesta no basta escribir la fórmula: debe indicarse dirección, intensidad, variables concretas y limitaciones.

Si se muestra como **heatmap**, la leyenda de color determina qué tono corresponde a valores positivos, negativos y cercanos a cero. No debe inferirse intensidad solo por “color oscuro” sin mirar esa escala.

Bloques de correlaciones altas pueden revelar grupos de variables redundantes; una fila casi neutra sugiere una variable poco asociada linealmente con las demás.

Respuesta modelo

Cashvent y Benvent presentan la asociación lineal más intensa, positiva y muy fuerte ($r = 0.958$). Aportan información parcialmente redundante y probablemente tendrán cargas semejantes en alguna componente. No puede concluirse que una cause la otra.

Plantilla adaptable al caso

“Entre *variable X* y *variable Y* se observa una asociación lineal *positiva/negativa* de intensidad *débil/moderada/fuerte*, porque $r = \dots$. En el contexto, cuando X tiende a aumentar, Y tiende a *aumentar/disminuir*. Esto describe asociación lineal y no permite afirmar causalidad; conviene revisar el diagrama de dispersión y posibles atípicos.”

8.3. Salida de PCA

Orden recomendado:

1. confirmar si los datos fueron estandarizados;
2. leer varianza individual y acumulada;
3. elegir cantidad de componentes con criterio explícito;
4. interpretar cargas de mayor valor absoluto;
5. describir puntajes/biplot;
6. declarar información perdida y posibles efectos de atípicos.

Respuesta modelo

Las dos primeras componentes explican 52.9 % de la variabilidad, por lo que el plano conserva algo más de la mitad y no resume completamente los datos. Con el criterio de Kaiser se retendrían tres componentes, cuyos valores propios superan 1 y acumulan 67.6 %. Si se exige al menos 80 %, serían necesarias cuatro. CP1 está definida principalmente por Cashvent y Benvent en el mismo sentido y Benrecpr en sentido contrario.

Salida de Colab

```
pca.explained_variance_
[2.119  1.580  1.026  0.881  0.836  0.535  0.024]

pca.explained_variance_ratio_
[0.303  0.226  0.147  0.126  0.119  0.076  0.003]
```

El primer arreglo contiene **valores propios**: varianza capturada por cada componente. El segundo divide cada valor propio por la varianza total y contiene proporciones. Así, 2.119 no es un porcentaje; su proporción correspondiente es 0.303, es decir, 30.3 %. Como las variables fueron estandarizadas, la suma de los valores propios es 7 y Kaiser conserva CP1, CP2 y CP3 por superar 1.

8.3.1. Matriz de pesos: salida prioritaria

	Cashvent	Ventact	Ventplan	Inmoactt	Benvent	Benrecpr	Bencap
CP1	0.657	0.069	0.110	-0.030	0.662	-0.311	0.122
CP2	-0.148	0.658	0.389	-0.621	-0.006	0.046	0.075
CP3	0.013	-0.117	0.409	0.253	-0.001	0.418	0.762
CP4	-0.119	0.027	-0.603	-0.273	-0.092	-0.380	0.628
CP5	0.190	0.105	-0.516	-0.210	0.245	0.761	-0.058
CP6	0.006	0.731	-0.200	0.649	-0.045	-0.043	0.027
CP7	0.704	0.046	0.011	-0.102	-0.701	0.023	0.009

Fuente: Cuaderno 3 IIA 2025, `pca.components_`.

Esta tabla y el mapa de calor mostrado anteriormente representan el mismo objeto. Para explicarlo en el parcial:

1. identificar que las filas son componentes y las columnas variables;
2. buscar en cada fila los pesos de mayor **valor absoluto**;
3. usar los signos para decidir si las variables actúan juntas o forman un contraste;
4. traducir la combinación al significado de las variables;
5. separar esta lectura de la varianza explicada, que proviene de otra salida.

Respuesta modelo para la matriz de pesos

CP1 está definida principalmente por Cashvent y Benvent, con pesos positivos similares de 0.657 y 0.662, y en sentido opuesto por Benrecpr, con -0.311 . Por lo tanto, puntajes altos en CP1 corresponden a observaciones con Cashvent y Benvent relativamente altos y Benrecpr relativamente bajo. CP2 contrasta Ventact (0.658) con Inmoactt (-0.621), mientras Ventplan acompaña moderadamente el lado positivo (0.389). CP3 está asociada sobre todo con Bencap (0.762), seguida por Benrecpr y Ventplan. Los coeficientes no son porcentajes de varianza explicada y el signo global de cada componente podría invertirse sin cambiar su significado.

Errores típicos al interpretar el heatmap de pesos

Un peso de 0.662 no significa que Benvent “explique 66.2%” de CP1. El color tampoco se interpreta sin mirar la escala. Deben compararse valores absolutos dentro de una fila, conservar los signos relativos y priorizar las componentes que efectivamente se hayan decidido retener. CP7 contrapone Cashvent y Benvent con pesos altos, pero explica apenas 0.3%: refleja principalmente la pequeña diferencia residual entre dos variables casi redundantes.

8.3.2. Puntajes o *scores*

Una tabla con columnas PC1, PC2, etc. y una fila por observación no es otra matriz de pesos. Son las nuevas coordenadas de los individuos. Por ejemplo, una observación con PC2 muy positivo se aproxima al perfil positivo de CP2: Ventact y Ventplan altos e Inmoactt bajo. Los puntajes permiten comparar casos, detectar extremos y construir el biplot; no indican cuánto participa cada variable en la componente.

8.4. Salida de atípicos multivariados

Salida de Colab

```
cutoff = chi2.ppf(0.95, 3)
7.814727903251179

outlierIndexes = np.where(distances > cutoff)
(array([55, 330, 359, 406, ..., 4370]),)
```

El corte 7.815 es el cuantil 95 % de una χ^2 con tres grados de libertad porque se analizaron tres variables. Los índices listados corresponden a filas cuya distancia de Mahalanobis al cuadrado supera ese corte; en el cuaderno se señalan 89 de 4372 clientes. La salida identifica casos potencialmente inusuales por su combinación de Gasto, Frecuencia y Días, pero no determina que sean errores ni autoriza por sí sola a eliminarlos.

8.5. Dendrograma

Respuesta modelo

Se observa un salto grande en la altura de las últimas fusiones. Un corte horizontal inmediatamente antes del salto produce tres grupos. Subir el corte reduce la cantidad y bajar el corte la aumenta. La solución depende de la estandarización, distancia y enlace; aquí Ward busca limitar el aumento de variabilidad interna.

Si aparecen varios dendrogramas, primero verificar que usen la misma distancia, escala y casos. Comparar solo la altura absoluta entre bases distintas puede ser engañoso; es más informativo observar qué observaciones permanecen juntas, dónde aparecen grandes saltos y qué solución obtiene mejor correlación cofenética o validación posterior.

8.6. Silueta e inercia

Salida de Colab

K	Silueta media
2	0.410
3	0.514
4	0.488
5	0.470
6	0.452
7	0.315
8	0.404

Respuesta modelo

Entre $K = 2$ y $K = 8$, la mayor silueta es 0.514 para $K = 3$, por lo que tres grupos ofrecen la mejor combinación observada de cohesión y separación. El valor indica estructura razonable, no fuerte. El codo y la interpretabilidad de los perfiles deberían respaldar esta elección.

En el gráfico del codo, el eje horizontal es K y el vertical la inercia. La curva siempre descende; interesa el cambio de pendiente, no que el último punto sea el menor. Si el codo es gradual y las siluetas son parecidas, no existe una cantidad indiscutible de grupos y debe priorizarse estabilidad e interpretación.

8.7. Centroides

Salida de Colab


Cluster	Cantidad	Gasto medio	Frecuencia media	Días medios
0	2 774	1 015.15	62.13	43.50
1	1 060	392.06	25.46	243.41
2	449	5 646.85	301.27	20.25

Respuesta modelo

El cluster con gasto 5646.85, frecuencia 301.27 y 20.25 días desde la última compra reúne clientes intensivos y recientes. Días debe leerse en sentido inverso: un valor pequeño indica mayor recencia. Su tamaño también debe revisarse antes de diseñar acciones comerciales.

Los boxplots por cluster permiten verificar si la diferencia de medias representa a la mayoría o está impulsada por pocos extremos. Cajas muy superpuestas indican poca separación en esa variable; medianas alejadas y cajas poco superpuestas indican capacidad discriminante. Brazos largos y numerosos puntos externos revelan heterogeneidad interna que el centroide oculta.

8.8. Comparación entre clustering jerárquico y K-means



Fuente: Cuaderno 4 IIA 2025, comparación de asignaciones.

Las etiquetas de los dos métodos no coinciden necesariamente: el cluster 1 de un algoritmo no tiene por qué ser el cluster 1 del otro. Por eso no se interpreta la diagonal como si fuera una matriz de clasificación supervisada. Se buscan correspondencias por las celdas grandes; por ejemplo, 2 293 observaciones del grupo jerárquico 2 pertenecen al grupo 2 de K-means, mientras 1 044 del grupo jerárquico 3 corresponden al grupo 0 de K-means.

Salida de Colab

```
ARI entre Jerárquico y KMeans: 0.660
AMI entre Jerárquico y KMeans: 0.647
Silueta Jerárquico: 0.457
Silueta KMeans: 0.514
```

Respuesta modelo

ARI y AMI muestran una concordancia apreciable, aunque no perfecta, entre las dos particiones. Estos índices no indican cuál es mejor ni representan exactitud, porque no hay una etiqueta verdadera. Para tres grupos, K-means obtiene mayor silueta que el método jerárquico, por lo que presenta mejor combinación interna de cohesión y separación en estos datos. La decisión final también debe considerar estabilidad, tamaños y significado de los perfiles.

9. Cómo las decisiones previas modifican los resultados

Los métodos multivariados no actúan sobre una realidad neutra, sino sobre la representación construida en la base. Cada decisión previa modifica la geometría de la nube y, por lo tanto, las componentes y los grupos obtenidos.

9.1. Efecto de la escala

Multiplicar una variable por una constante multiplica su varianza por el cuadrado de esa constante y altera las distancias euclídeas. En PCA sobre covarianzas, esa variable puede dominar los primeros ejes; en K-means o Ward, puede dominar las fusiones y asignaciones. Estandarizar evita el dominio puramente numérico, pero también elimina diferencias reales de variabilidad. La elección debe justificarse por el significado de las unidades.

9.2. Efecto de los atípicos

Un extremo puede desplazar la media, aumentar varianzas y covarianzas, rotar las componentes, mover centroides de K-means y provocar ramas aisladas en un dendrograma. Eliminarlo puede revelar la estructura de la mayoría, pero también ocultar un segmento genuino. Por eso es útil comparar soluciones con y sin casos señalados y describir qué cambia.

9.3. Efecto de los faltantes y la imputación

La eliminación por casos completos puede cambiar la composición de la muestra. La imputación por media introduce observaciones artificialmente centrales: reduce dispersión y puede aumentar la aparente densidad alrededor del centro. En PCA puede reducir determinados valores propios; en clustering puede favorecer grupos más compactos de forma artificial. Siempre debe conocerse cuántos casos se eliminaron o imputaron.

9.4. Efecto de variables redundantes e irrelevantes

Incluir varias variables casi equivalentes pondera repetidamente el mismo fenómeno en una distancia. PCA puede condensar esa redundancia; otra posibilidad es seleccionar variables con fundamento sustantivo. Variables irrelevantes agregan dimensiones de ruido, vuelven menos contrastantes las distancias y pueden deteriorar la silueta.

En alta dimensión, las distancias entre pares tienden a parecerse y la noción de “vecino cercano” pierde contraste. Reducir dimensión puede ayudar, siempre que las componentes conservadas mantengan la estructura relevante.

9.5. Efecto de la elección del método

El enlace simple favorece continuidad y cadenas; el completo y Ward favorecen compacidad; K-means favorece grupos alrededor de medias. Dos resultados diferentes no implican que uno contenga un error: pueden estar imponiendo nociones distintas de grupo. La comparación debe considerar el objetivo, la geometría esperada, índices de validación y perfiles obtenidos.

Lectura integrada de una salida

Una conclusión completa debe reconstruir el proceso: unidad de análisis, variables incluidas, tratamiento de escala/faltantes/atípicos, método aplicado, criterio de selección y significado de la solución. Un valor aislado —por ejemplo, silueta 0.514 o varianza acumulada 80.2%— solo es interpretable dentro de esa cadena.